

# 逻辑回归

2021-09-05

## 1. 广义线性模型

- 1.1. 指数族分布
- 1.2. 广义线性模型的假设

## 2. 逻辑回归

- 2.1. 模型推导
- 2.2. 极大似然估计
  - 2.2.1. 似然函数形式一
  - 2.2.2. 似然函数形式二
- 2.3. 模型求解

## 3. 参考文献

# 1. 广义线性模型

## 1.1. 指数族分布

指数族 (Exponential Family) 分布是一类分布的总称, 该类分布的分布律 (或概率密度函数) 的一般形式为:

$$p(y; \eta) = b(y) \cdot e^{(\eta^T T(y) - a(\eta))} \quad (21)$$

各符号含义如下:

- 1.  $\eta$  为该分布的自然参数, 可为向量
- 2.  $T(y)$  为充分统计量, 视具体的分布而定, 通常等于随机变量  $y$  本身
- 3.  $a(\eta)$  为配分函数
- 4.  $b(y)$  为关于随机变量  $y$  的函数

常见的伯努利分布和正态分布均属于指数族分布。以下证明伯努利分布属于指数族分布:

已知伯努利分布的分布律为:

$$p(y) = \phi^y (1 - \phi)^{1-y} \quad (22)$$

其中,  $y \in \{0, 1\}$ ,  $\phi$  为  $y = 1$  的概率, 即  $p(y = 1) = \phi$

对上式恒等变形得:

$$\begin{aligned} p(y) &= \phi^y (1 - \phi)^{1-y} \\ &= \exp(\ln(\phi^y (1 - \phi)^{1-y})) \\ &= \exp(\ln \phi^y + \ln (1 - \phi)^{1-y}) \\ &= \exp(y \ln \phi + (1 - y) \ln (1 - \phi)) \end{aligned} \quad (23)$$

$$\begin{aligned}
&= \exp(y \ln \phi + \ln(1 - \phi) - y \ln(1 - \phi)) \\
&= \exp(y(\ln \phi - \ln(1 - \phi)) + \ln(1 - \phi)) \\
&= \exp\left(y \ln\left(\frac{\phi}{1 - \phi}\right) + \ln(1 - \phi)\right)
\end{aligned} \tag{23}$$

对比指数族分布的一般形式  $p(y; \eta) = b(y) \cdot e^{(\eta^T T(y) - a(\eta))}$ ，可知：

$$\begin{aligned}
b(y) &= 1 \\
\eta &= \ln\left(\frac{\phi}{1 - \phi}\right) \\
T(y) &= y \\
a(\eta) &= -\ln(1 - \phi) = \ln(1 + e^\eta)
\end{aligned} \tag{24}$$

由此说明，伯努利分布为指数族分布。

## 1.2. 广义线性模型的假设

1. 在给定 $x$ 的条件下，假设随机变量 $y$ 服从某个指数族分布
2. 在给定 $x$ 的条件下，我们的目标是得到一个模型 $h(x)$ 能预测出 $T(y)$ 的期望值
3. 假设该指数族分布中的自然参数 $\eta$ 和 $x$ 呈线性关系，即 $\eta = w^T x$

## 2. 逻辑回归

### 2.1. 模型推导

逻辑回归是对二分类问题进行建模，并且假设被建模的随机变量 $y$ 取值为0或1，因此，可以很自然地假设 $y$ 服从伯努利分布。此时，如果希望构建一个线性模型来预测给定 $x$ 的条件下 $y$ 取值的话，可以考虑使用广义线性模型来进行建模。

已知 $y$ 服从伯努利分布，而伯努利分布属于指数族分布，所以满足广义线性模型的三条假设。根据第二条假设，可以推出模型 $h(x)$ 的表达式为：

$$h(x) = E[T(y | x)] \tag{25}$$

注意， $y | x$ 只是表示形式，并不影响 $T(y)$ 的计算，即 $T(y | x) = T(y)$ 。根据伯努利分布的 $T(y | x) = y | x$ ，所以：

$$h(x) = E(y | x) \tag{26}$$

又因为 $E[y | \mathbf{x}] = 1 \times p(y = 1 | \mathbf{x}) + 0 \times p(y = 0 | \mathbf{x}) = p(y = 1 | \mathbf{x}) = \phi$ ，所以：

$$h(x) = \phi \tag{27}$$

根据公式(4)  $\eta = \ln\left(\frac{\phi}{1 - \phi}\right)$ 可知，对伯努利分布：

$$\frac{1}{1 + e^{-\eta}} = \phi \tag{28}$$

将 $\phi$ 带入 $h(x)$ 得：

$$h(\mathbf{x}) = \phi = \frac{1}{1 + e^{-\eta}} \tag{29}$$

根据广义线性模型的第三条假设  $\eta = w^T x$ ， $h(x)$ 最终可简化为：

$$h(\mathbf{x}) = \phi = \frac{1}{1 + e^{-w^T \mathbf{x}}} = p(y = 1 | \mathbf{x}) \tag{30}$$

此即为逻辑回归模型。

## 2.2. 极大似然估计

已知随机变量 $y$ 取1和0的概率分别为（考虑偏置项）：

$$p(y = 1 | \mathbf{x}) = \frac{e^{\mathbf{w}^T \mathbf{x} + b}}{1 + e^{\mathbf{w}^T \mathbf{x} + b}} p(y = 0 | \mathbf{x}) = \frac{1}{1 + e^{\mathbf{w}^T \mathbf{x} + b}} \quad (31)$$

令 $\boldsymbol{\beta} = (\mathbf{w}; b)$ ,  $\hat{\mathbf{x}} = (\mathbf{x}; 1)$ , 则 $\mathbf{w}^T \mathbf{x} + b$ 可简写为 $\boldsymbol{\beta}^T \hat{\mathbf{x}}$ , 于是上式可化简为：

$$p(y = 1 | \mathbf{x}) = \frac{e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}}}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}}} = p_1(\hat{\mathbf{x}}; \boldsymbol{\beta}) p(y = 0 | \mathbf{x}) = \frac{1}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}}} = p_0(\hat{\mathbf{x}}; \boldsymbol{\beta}) \quad (32)$$

将上式合并得：

$$p(y | \mathbf{x}; \mathbf{w}, b) = y \cdot p_1(\hat{\mathbf{x}}; \boldsymbol{\beta}) + (1 - y) \cdot p_0(\hat{\mathbf{x}}; \boldsymbol{\beta}) \quad (33)$$

或者：

$$p(y | \mathbf{x}; \mathbf{w}, b) = [p_1(\hat{\mathbf{x}}; \boldsymbol{\beta})]^y [p_0(\hat{\mathbf{x}}; \boldsymbol{\beta})]^{1-y} \quad (34)$$

根据对数似然函数的定义可知：

$$\ln L(\mathbf{w}) = \sum_{i=1}^m \ln f(y_i, w_1, w_2, \dots, w_k) \quad (35)$$

因此，逻辑回归的对数似然函数可以表示为：

$$\ell(\mathbf{w}, b) := \ln L(\mathbf{w}, b) = \sum_{i=1}^m \ln p(y_i | \mathbf{x}_i; \mathbf{w}, b) \quad (36)$$

根据 $p(y | \mathbf{x}; \mathbf{w}, b)$ 的两种形式（公式(13)和公式(14)），可以得到两种对数似然函数，以下将分别推导。

### 2.2.1. 似然函数形式一

将 $p(y | \mathbf{x}; \mathbf{w}, b) = y \cdot p_1(\hat{\mathbf{x}}; \boldsymbol{\beta}) + (1 - y) \cdot p_0(\hat{\mathbf{x}}; \boldsymbol{\beta})$ 带入似然函数（公式(16)）可得：

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^m \ln (y_i p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta}) + (1 - y_i) p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta})) \quad (37)$$

由于 $p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta}) = \frac{e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}}$ ， $p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta}) = \frac{1}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}}$ ，上式可化简为：

$$\begin{aligned} \ell(\boldsymbol{\beta}) &= \sum_{i=1}^m \ln \left( \frac{y_i e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}} + \frac{1 - y_i}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}} \right) \\ &= \sum_{i=1}^m \ln \left( \frac{y_i e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i} + 1 - y_i}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}} \right) \\ &= \sum_{i=1}^m \left( \ln (y_i e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i} + 1 - y_i) - \ln (1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}) \right) \end{aligned} \quad (38)$$

由于 $y_i \in \{0, 1\}$ ，所以

$$\begin{aligned}
& \ln \left( y_i e^{\beta^T \hat{\mathbf{x}}_i} + 1 - y_i \right) - \ln \left( 1 + e^{\beta^T \hat{\mathbf{x}}_i} \right) \\
&= \ln \left( 0 \cdot e^{\beta^T \hat{\mathbf{x}}_i} + 1 - 0 \right) - \ln \left( 1 + e^{\beta^T \hat{\mathbf{x}}_i} \right) \\
&\text{当 } y_i = 0 \text{ 时,} \\
&= \ln 1 - \ln \left( 1 + e^{\beta^T \hat{\mathbf{x}}_i} \right) \\
&= -\ln \left( 1 + e^{\beta^T \hat{\mathbf{x}}_i} \right) \\
&\ln \left( y_i e^{\beta^T \hat{\mathbf{x}}_i} + 1 - y_i \right) - \ln \left( 1 + e^{\beta^T \hat{\mathbf{x}}_i} \right) \\
&\text{当 } y_i = 1 \text{ 时,} = \ln \left( 1 \cdot e^{\beta^T \hat{\mathbf{x}}_i} + 1 - 1 \right) - \ln \left( 1 + e^{\beta^T \hat{\mathbf{x}}_i} \right) \\
&= \beta^T \hat{\mathbf{x}}_i - \ln \left( 1 + e^{\beta^T \hat{\mathbf{x}}_i} \right)
\end{aligned}$$

综合可得：

$$\ell(\beta) = \sum_{i=1}^m \left( y_i \beta^T \hat{\mathbf{x}}_i - \ln \left( 1 + e^{\beta^T \hat{\mathbf{x}}_i} \right) \right) \quad (39)$$

### 2.2.2. 似然函数形式二

若  $p(y | \mathbf{x}; \mathbf{w}, b) = [p_1(\hat{\mathbf{x}}; \beta)]^y [p_0(\hat{\mathbf{x}}; \beta)]^{1-y}$ ，将其带入对数似然可得：

$$\begin{aligned}
\ell(\beta) &= \sum_{i=1}^m \ln \left( [p_1(\hat{\mathbf{x}}_i; \beta)]^{y_i} [p_0(\hat{\mathbf{x}}_i; \beta)]^{1-y_i} \right) \\
&= \sum_{i=1}^m \left[ \ln \left( [p_1(\hat{\mathbf{x}}_i; \beta)]^{y_i} \right) + \ln \left( [p_0(\hat{\mathbf{x}}_i; \beta)]^{1-y_i} \right) \right] \\
&= \sum_{i=1}^m \left[ y_i \ln(p_1(\hat{\mathbf{x}}_i; \beta)) + (1 - y_i) \ln(p_0(\hat{\mathbf{x}}_i; \beta)) \right] \\
&= \sum_{i=1}^m \left\{ y_i [\ln(p_1(\hat{\mathbf{x}}_i; \beta)) - \ln(p_0(\hat{\mathbf{x}}_i; \beta))] + \ln(p_0(\hat{\mathbf{x}}_i; \beta)) \right\} \quad (40) \\
&= \sum_{i=1}^m \left[ y_i \ln \left( \frac{p_1(\hat{\mathbf{x}}_i; \beta)}{p_0(\hat{\mathbf{x}}_i; \beta)} \right) + \ln(p_0(\hat{\mathbf{x}}_i; \beta)) \right] \\
&= \sum_{i=1}^m \left[ y_i \ln \left( e^{\beta^T \hat{\mathbf{x}}_i} \right) + \ln \left( \frac{1}{1 + e^{\beta^T \hat{\mathbf{x}}_i}} \right) \right] \\
&= \sum_{i=1}^m \left( y_i \beta^T \hat{\mathbf{x}}_i - \ln \left( 1 + e^{\beta^T \hat{\mathbf{x}}_i} \right) \right)
\end{aligned}$$

### 2.3. 模型求解

对似然函数  $\ell(\beta)$  求极大，或求损失函数  $-\ell(\beta)$  的极小。

## 3. 参考文献

1. Andrew Ng. cs229-notes1

