

# PCA

2021-10-06

## 1. 背景知识

## 2. PCA原理

2. 1. 降维概述

2. 2. 原理推导

## 3. PCA求解

3. 1. 协方差矩阵的特征值分解法

3. 2. 数据矩阵的奇异值分解算法

3. 3. 示例

## 4. 参考链接

# 1. 背景知识

### 1. 协方差

$X$ 、 $Y$ 为两个一维随机变量，它们的协方差为：

$$\begin{aligned}\text{cov}(X, Y) &= E[(X - E[X])(Y - E[Y])] \\ &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1}\end{aligned}\quad (35)$$

### 2. 协方差矩阵

对多维随机变量 $\mathbf{X}$ ：

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1n} \\ x_{21} & x_{22} & \cdots & x_{2n} \\ \vdots & \vdots & \cdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{mn} \end{pmatrix}_{m \times n} = [\mathbf{X}_1, \mathbf{X}_2, \cdots, \mathbf{X}_n] \quad (36)$$

其中， $\mathbf{X}_i = [x_{1i}, x_{2i}, \cdots, x_{mi}]$ ，为列向量

计算其两两维度之间的协方差，各协方差组成了一个 $n \times n$ 的矩阵，称为协方差矩阵，记为 $\Sigma$ 。矩阵内的元素 $\Sigma_{ij}$ ：

$$\Sigma_{ij} = \text{cov}(X_i, X_j) = E[(X_i - E[X_i])(X_j - E[X_j])] \quad (37)$$

样本协方差矩阵：

$$\begin{aligned}\Sigma &= E[(\mathbf{X} - E[\mathbf{X}])(\mathbf{X} - E[\mathbf{X}])^T] \\ &= \frac{1}{m - 1}(\mathbf{X} - E[\mathbf{X}])(\mathbf{X} - E[\mathbf{X}])^T\end{aligned}\quad (38)$$

若 $\mathbf{X}$ 的列均值为0，则：


$$\begin{aligned}\Sigma &= \mathbb{E} [(\mathbf{X} - \mathbb{E}[\mathbf{X}])(\mathbf{X} - \mathbb{E}[\mathbf{X}])^T] \\ &= \mathbb{E} [\mathbf{X}^T \mathbf{X}] \\ &= \frac{1}{m-1} \mathbf{X}^T \mathbf{X}\end{aligned}\tag{39}$$

## 2. PCA原理

### 2.1. 降维概述

不加思索地认为，对矩阵 $\mathbf{X}$ 通过线性变换降维后，数据越分散，效果越好。如何度量数据的分散程度？各维度的方差越大，数据越分散。概括一下，降维后，各维度方差越大，降维效果越好。

举例：将二维数据降到一维，如果集中到了一点，那么数据就不具备可分性，自然可以认为降维效果不好。说明降维后数据越分散、越具有可分性，降维效果越好。在PCA中，选择“方差”作为衡量数据分散性的指标。



降维概述：给定原始矩阵 $\mathbf{X}_{m \times n}$ 及线性变换矩阵 $\mathbf{A}_{n \times k}$ ，通过 $\mathbf{X}\mathbf{A}$ 线性变换，将矩阵 $\mathbf{X}_{m \times n}$ 由 $n$ 维降到 $k$ 维，得到矩阵 $\mathbf{Y}_{m \times k}$ ，降维后的维度 $k$ ，又称为主成分个数。

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1n} \\ x_{21} & x_{22} & \cdots & x_{2n} \\ \vdots & \vdots & \cdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{mn} \end{pmatrix}_{m \times n}\tag{40}$$

### 2.2. 原理推导

假设：

1. 已经对矩阵 $\mathbf{X}_{m \times n}$ 做了标准化，其均值 $\mu = 0$ 。
2. 矩阵 $\mathbf{A}_{n \times d}$ 为正交矩阵。

首先，考虑求第一主成分：

$$\mathbf{y}_1 = \mathbf{X}\mathbf{a}_1\tag{41}$$

其中， $\mathbf{a}_1 = \{a_{11}, a_{21}, \dots, a_{n1}\}^T$

求 $\mathbf{y}_1$ 的方差：

$$\begin{aligned}
\text{var}(\mathbf{y}_1) &= E\{(\mathbf{X}\mathbf{a}_1 - \mu\mathbf{a}_1)^\top(\mathbf{X}\mathbf{a}_1 - \mu\mathbf{a}_1)\} \\
&= \mathbf{a}_1^\top E\{(\mathbf{X} - \mu)^\top(\mathbf{X} - \mu)\}\mathbf{a}_1 \\
&= \mathbf{a}_1^\top E\{\mathbf{X}^\top\mathbf{X}\}\mathbf{a}_1 \\
&= \mathbf{a}_1^\top \Sigma \mathbf{a}_1
\end{aligned} \tag{42}$$

其中， $\Sigma$ 为矩阵 $\mathbf{X}$ 的协方差矩阵

优化目标：

$$\begin{aligned}
&\max \quad \mathbf{a}_1^\top \Sigma \mathbf{a}_1 \\
&s.t. \quad \mathbf{a}_1^\top \mathbf{a}_1 = 1
\end{aligned} \tag{43}$$

定义拉格朗日函数：

$$L(\mathbf{a}_1, \lambda) = \mathbf{a}_1^\top \Sigma \mathbf{a}_1 - \lambda(\mathbf{a}_1^\top \mathbf{a}_1 - 1) \tag{44}$$

求函数 $L(\mathbf{a}_1, \lambda)$ 对 $\mathbf{a}_1$ 的导数并令导数为0：

$$\frac{\partial L}{\partial \mathbf{a}_1} = \Sigma \mathbf{a}_1 - \lambda \mathbf{a}_1 = 0 \tag{45}$$

求得：

$$\Sigma \mathbf{a}_1 = \lambda \mathbf{a}_1 \tag{46}$$

所以， $\lambda$ 为协方差矩阵 $\Sigma$ 的特征值， $\mathbf{a}_1$ 为对应的单位特征向量。

进一步，优化目标可化简为：

$$\mathbf{a}_1^\top \Sigma \mathbf{a}_1 = \mathbf{a}_1^\top \lambda \mathbf{a}_1 = \lambda \mathbf{a}_1^\top \mathbf{a}_1 = \lambda \tag{47}$$

假设 $\mathbf{a}_1$ 是 $\Sigma$ 的第一大特征值 $\lambda_1$ 对应的单位特征向量，显然， $\mathbf{a}_1$ 和 $\lambda_1$ 是以上问题的最优解。

然后，考虑求第二主成分：

$$\begin{aligned}
&\max \quad \mathbf{a}_2^\top \Sigma \mathbf{a}_2 \\
&s.t. \quad \mathbf{a}_1^\top \Sigma \mathbf{a}_2 = 0 \\
&\quad \mathbf{a}_2^\top \Sigma \mathbf{a}_1 = 0 \\
&\quad \mathbf{a}_1^\top \mathbf{a}_2 = 0 \\
&\quad \mathbf{a}_2^\top \mathbf{a}_1 = 0 \\
&\quad \mathbf{a}_2^\top \mathbf{a}_2 = 1
\end{aligned} \tag{48}$$

注意到：

$$\mathbf{a}_1^\top \Sigma \mathbf{a}_2 = \mathbf{a}_2^\top \Sigma \mathbf{a}_1 = \mathbf{a}_2^\top \lambda_1 \mathbf{a}_1 = \lambda_1 \mathbf{a}_2^\top \mathbf{a}_1 = \lambda_1 \mathbf{a}_1^\top \mathbf{a}_2 = 0 \tag{49}$$

说明，等式约束是等价的。

定义拉格朗日函数：

$$L(\mathbf{a}_2, \lambda, \phi) = \mathbf{a}_2^\top \Sigma \mathbf{a}_2 - \lambda(\mathbf{a}_2^\top \mathbf{a}_2 - 1) - \phi \mathbf{a}_2^\top \mathbf{a}_1 \tag{50}$$

求函数 $L(\mathbf{a}_2, \lambda)$ 对 $\mathbf{a}_2$ 的导数并令导数为0：

$$\frac{\partial L}{\partial \mathbf{a}_2} = 2\Sigma \mathbf{a}_2 - 2\lambda \mathbf{a}_2 - \phi \mathbf{a}_1 = 0 \tag{51}$$

将上式左乘以 $\mathbf{a}_1^\top$ 得：

$$2\mathbf{a}_1^\top \Sigma \mathbf{a}_2 - 2\lambda \mathbf{a}_1^\top \mathbf{a}_2 - \phi \mathbf{a}_1^\top \mathbf{a}_1 = 0 \tag{52}$$

此式前两项为0, 且 $\mathbf{a}_1^T \mathbf{a}_1 = 1$ , 所以,  $\phi = 0$ 。根据式(12)可得:

$$\Sigma \mathbf{a}_2 - \lambda \mathbf{a}_2 = 0 \quad (53)$$

所以,  $\lambda$ 是协方差矩阵 $\Sigma$ 的特征值,  $\mathbf{a}_2$ 为对应的单位特征向量。于是, 目标函数:

$$\mathbf{a}_2^T \Sigma \mathbf{a}_2 = \mathbf{a}_2^T \lambda \mathbf{a}_2 = \lambda \mathbf{a}_2^T \mathbf{a}_2 = \lambda \quad (54)$$

假设 $\mathbf{a}_2$ 是 $\Sigma$ 的第二大特征值 $\lambda_2$ 对应的单位特征向量, 显然,  $\mathbf{a}_2$ 和 $\lambda_2$ 是以上问题的最优解。

一般地,  $\mathbf{A}_{n \times d}$ 的第 $k$ 主成分是 $\mathbf{y}_k = \mathbf{X} \mathbf{a}_k$ , 并且 $\text{var}(\mathbf{y}_k) = \lambda_k$ , 这里 $\lambda_k$ 为 $\Sigma$ 第 $k$ 大的特征值并且 $\mathbf{a}_k$ 为对应的单位特征向量。

综上所述, 为将 $\mathbf{X}_{m \times n}$ 进行降维, 只要求其协方差矩阵的特征向量即可。

## 3. PCA求解

### 3.1. 协方差矩阵的特征值分解法

#### 1. 数据规范化处理

将 $\mathbf{X}_{m \times n}$ 做规范化处理, 处理后, 每一列的均值为0。

$$\mathbf{X}_{m \times n} = \frac{\mathbf{X}_{m \times n} - \text{每列均值}}{\text{每列标准差}} \quad (55)$$

#### 2. 计算协方差矩阵

$$\Sigma = \frac{1}{m-1} \mathbf{X}^T \mathbf{X} \quad (56)$$

#### 3. 求协方差矩阵的特征值和特征向量

特征值(从大到小排列):  $\lambda_1, \lambda_2, \dots, \lambda_k$

特征向量:  $\mathbf{A}_{n \times k} = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_k]$ ,  $\mathbf{a}_i = [a_{1i}, a_{2i}, \dots, a_{ni}]^T$

#### 4. 求 $k$ 个主成分

$$\mathbf{Y}_{m \times k} = \mathbf{X}_{m \times n} \mathbf{A}_{n \times k} \quad (57)$$

#### 5. 计算 $k$ 个主成分的方差贡献率

$$\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^n \lambda_i} \quad (58)$$

### 3.2. 数据矩阵的奇异值分解算法

给定矩阵 $\mathbf{X}_{m \times n}$ , 并且该矩阵每列均值为0。构造一个新矩阵:

$$\mathbf{X}' = \frac{1}{\sqrt{m-1}} \mathbf{X} \quad (59)$$

那么:

$$\mathbf{X}'^T \mathbf{X}' = \left( \frac{1}{\sqrt{m-1}} \mathbf{X} \right)^T \left( \frac{1}{\sqrt{m-1}} \mathbf{X} \right) \quad (60)$$

$$\begin{aligned}
&= \frac{1}{m-1} \mathbf{X}^T \mathbf{X} \\
&= \mathbf{S}
\end{aligned}$$

不难得知， $\mathbf{S}$ 为 $\mathbf{X}$ 的协方差矩阵。

根据SVD分解定理：

$$\begin{aligned}
\mathbf{X}' &= \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T \\
\mathbf{S} &= \mathbf{X}'^T \mathbf{X}' = \mathbf{V} (\mathbf{\Sigma}^T \mathbf{\Sigma}) \mathbf{V}^T
\end{aligned} \tag{61}$$

所以， $\mathbf{V}$ 为协方差矩阵 $\mathbf{S}$ 的特征向量，同时也是 $\mathbf{X}'$ 的右奇异矩阵。

至此，将求解矩阵 $\mathbf{X}_{m \times n}$ 协方差矩阵的特征向量，转为求解矩阵 $\mathbf{X}'$ 的右奇异矩阵。

基于SVD分解的PCA降维求解过程：

1. 构造新矩阵

$$\mathbf{X}' = \frac{1}{\sqrt{m-1}} \mathbf{X} \tag{62}$$

2. 对矩阵 $\mathbf{X}'$ 进行截断奇异值分解

$$\mathbf{X}' \approx \mathbf{U}_k \mathbf{\Sigma}_k \mathbf{V}_k^T \tag{63}$$

其中， $\mathbf{U}_k$ 是 $m \times k$ 矩阵， $\mathbf{\Sigma}_k$ 是 $k$ 阶对角矩阵， $\mathbf{V}_k$ 是 $n \times k$ 矩阵

矩阵 $\mathbf{V}_k$ 是 $k$ 个样本主成分的线性变换矩阵。

3. 降维： $n$ 维  $\rightarrow$   $k$ 维

$$\mathbf{Y}_{m \times k} = \mathbf{X} \mathbf{V}_k \tag{64}$$

### 3.3. 示例

问题：给定矩阵 $\mathbf{X}$ ，从2维降到1维。

$$\mathbf{X} = \begin{vmatrix} -1, & -2 \\ -1, & 0 \\ 0, & 0 \\ 2, & 1 \\ 0, & 1 \end{vmatrix}_{5 \times 2} \tag{65}$$

降维步骤：

1. 数据标准化处理：减均值，除以标准差

$$\mathbf{X} = \begin{vmatrix} -0.91, & -1.83 \\ -0.91, & 0 \\ 0, & 0 \\ 1.83, & 0.91 \\ 0, & 0.91 \end{vmatrix}_{5 \times 2} \tag{66}$$

2. 求协方差矩阵

$$\mathbf{S} = \begin{vmatrix} 1.25, & 0.83 \\ 0.83, & 1.25 \end{vmatrix}_{5 \times 2} \tag{67}$$

3. 求协方差矩阵的特征值和特征向量

特征值:  $[2.08, 0.42]$

特征向量:  $[[0.71, 0.71], [-0.71, 0.71]]$


4. 求降维后的数据 (第一主成分)

$$\mathbf{X}_{new} = \begin{bmatrix} -2.12 \\ -0.71 \\ 0 \\ 2.12 \\ 0.71 \end{bmatrix}_{5 \times 2} \quad (68)$$

5. 求第一主成分的方差贡献

$$2.08 / (2.08 + 0.42) = 0.83$$

降维结果可视化:



## 4. 参考链接

1. [PCA与SVD应用中负号问题 - 深海里的猫 - 博客园 \(cnblogs.com\)](http://cnblogs.com)
2. [主成分分析 \(Principle Component Analysis\) - swolf的博客 \(mrswolf.github.io\)](https://mrswolf.github.io)
3. [使用numpy来理解PCA和SVD - 知乎 \(zhihu.com\)](https://zhihu.com)
4. [CodingLabs - PCA的数学原理](#)