

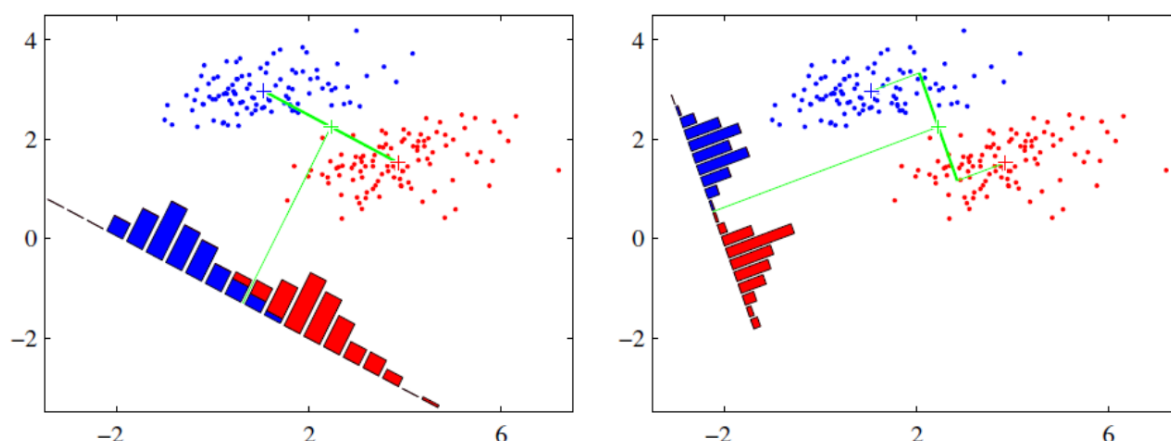
线性判别分析(LDA)

2021-10-24

1. 基本原理
2. 降维步骤
3. 参考链接

1. 基本原理

降维原理：组间方差大、组内方差小。



2. 降维步骤

以二类数据为例对降维过程进行说明。首先，定义如下变量：

1. 数据集： $\mathbf{x}^{(i)} = [x_1^{(i)}, x_2^{(i)}, \dots, x_d^{(i)}]^T$ ，共 N 个样本
2. 类别： $c = \{c_1, c_2\}$ ，其中， c_1 样本个数为 N_1 ， c_2 样本个数为 N_2 ， $N = N_1 + N_2$

原始数据为 d 维，在“组间方差大、组内方差小”的原则下，先降1维；

1. 投影

使用向量 $\mathbf{w} = [w_1, w_2, \dots, w_d]^T$ 对数据进行投影，并得到投影后的结果：

$$\mathbf{y} = \mathbf{w}^T \mathbf{x} \quad (18)$$

2. 计算原始数据类内均值

$$\mu_i = \frac{1}{N_i} \sum_{\mathbf{x} \in c_i} \mathbf{x} \{1, 2\}, \mu_i \text{的维度是 } d \times 1 \quad (19)$$

3. 计算投影后的样本点均值

$$\tilde{\mu}_i = \frac{1}{N_i} \sum_{y \in c_i} y = \frac{1}{N_i} \sum_{y \in c_i} \mathbf{w}^T \mathbf{x} = \mathbf{w}^T \mu_i \quad (20)$$

由此可知，投影后的均值是样本中心点的投影。

4. 定义投影后数据的方差：度量组内差异

$$\begin{aligned} \tilde{s}_i^2 &= \sum_{y \in c_i} (y - \tilde{\mu}_i)^2 \\ &= \sum_{\mathbf{x} \in c_i} (\mathbf{w}^T \mathbf{x} - \mathbf{w}^T \mu_i)^2 \\ &= \sum_{\mathbf{x} \in c_i} \mathbf{w}^T (\mathbf{x} - \mu_i)(\mathbf{x} - \mu_i)^T \mathbf{w} \end{aligned} \quad (21)$$

\tilde{s}_i^2 的几何意义是反映了样本点的密集程度，值越大，投影后数据越分散，反之，越集中。

为方便后续计算，定义中间部分为：

$$S_i = \sum_{\mathbf{x} \in c_i} (\mathbf{x} - \mu_i)(\mathbf{x} - \mu_i)^T \quad (22)$$

注： S_i 的维度是 $d \times d$

这也被称为散列矩阵（scatter matrices）。

定义 S_W （**Within**-class scatter matrix）为：

$$S_W = S_1 + S_2 \text{的维度是 } d \times d \quad (23)$$

5. 定义投影后组间均值差异：度量组间差异

$$\begin{aligned} A &= (\tilde{\mu}_1 - \tilde{\mu}_2)^2 \\ &= (\mathbf{w}^T \mu_1 - \mathbf{w}^T \mu_2)(\mathbf{w}^T \mu_1 - \mathbf{w}^T \mu_2)^T \\ &= \mathbf{w}^T (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T \mathbf{w} \end{aligned} \quad (24)$$

定义 S_B 称为（**Between**-class scatter matrix）：

$$S_B = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T \quad (25)$$

注： S_B 的维度是 $d \times d$

6. 定义最终度量公式

$$\begin{aligned} J(w) &= \frac{(\tilde{\mu}_1 - \tilde{\mu}_2)^2}{\tilde{s}_1^2 + \tilde{s}_2^2} \\ &= \frac{\mathbf{w}^T S_B \mathbf{w}}{\mathbf{w}^T S_W \mathbf{w}} \end{aligned} \quad (26)$$

7. 定义优化目标

$$\begin{aligned} &\max J(\mathbf{w}) \\ &s.t. \quad \|\mathbf{w}^T S_W \mathbf{w}\| = 1 \end{aligned} \quad (27)$$

增加约束 $\|\mathbf{w}^T S_W \mathbf{w}\| = 1$ 的原因：因为不做归一化的话， \mathbf{w} 扩大任何倍，公式都成立，因此无法确定 \mathbf{w} 。

8. 定义拉格朗日函数

$$\mathcal{L}(\mathbf{w}, \lambda) = \mathbf{w}^T S_B \mathbf{w} - \lambda (\mathbf{w}^T S_W \mathbf{w} - 1) \quad (28)$$

求导得：

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial \mathbf{w}} &= S_B \mathbf{w} + S_B^T \mathbf{w} - \lambda S_W \mathbf{w} - \lambda S_W^T \mathbf{w} \\ &= 2S_B \mathbf{w} - 2\lambda S_W \mathbf{w} \quad (\text{因为 } S_B \text{ 和 } S_W \text{ 为对称矩阵}) \\ &= 0 \end{aligned} \quad (29)$$

解得：

$$S_B \mathbf{w} = \lambda S_W \mathbf{w} S_W^{-1} S_B \mathbf{w} = \lambda \mathbf{w} \quad (30)$$

可见， \mathbf{w} 是矩阵 $S_W^{-1} S_B$ 的特征向量，当前可以取最大特征值对应的特征向量。

因为：

$$S_B \mathbf{w} = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \mathbf{w} \quad (31)$$

而 $(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \mathbf{w}$ 为一个数值，假设 $(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \mathbf{w} = \alpha$ ，那么总可以对 \mathbf{w} 进行缩放，使得 $\alpha = \lambda$ ，即：

$$S_B \mathbf{w} = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \mathbf{w} = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) \lambda \quad (32)$$

那么：

$$S_W^{-1} S_B \mathbf{w} = S_W^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) \lambda = \lambda \mathbf{w} \quad (33)$$

所以：

$$\mathbf{w} = S_W^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) \quad (34)$$

至此，只要求出原始样本的均值和方差就可以求出最佳的方向 \mathbf{w} 。

3. 参考链接

1. [线性判别分析LDA原理总结 - 刘建平Pinard - 博客园 \(cnblogs.com\)](http://cnblogs.com)
2. [为什么线性判别分析的降维维数不能大于类别数减一？ - 知乎 \(zhihu.com\)](http://zhihu.com)
3. [Dimensionality Reduction——LDA线性判别分析原理篇 - 知乎 \(zhihu.com\)](http://zhihu.com)
4. [Linear Discriminant Analysis \(sebastianraschka.com\)](http://sebastianraschka.com)