

高斯混合模型

2021-8-14

1. 高斯混合模型

- 1.1. 模型定义
- 1.2. 假设的生成过程
- 1.3. 求后验分布
- 1.4. 聚类

2. 参数求解

- 2.1. 极大似然估计
 - 2.1.1. 求 μ_i
 - 2.1.2. 求 σ_i
 - 2.1.3. 求 α_i
 - 2.1.4. 迭代过程
- 2.2. EM算法
 - 2.2.1. 完全数据的对数似然函数
 - 2.2.2. E步：确定Q函数
 - 2.2.3. M步：Q函数最大化

3. 例子

4. 参考文档

1. 高斯混合模型

1.1. 模型定义

$$P_M(x) = \sum_{i=1}^k \alpha_i \cdot \phi(x|\mu_i, \sigma_i^2) \quad (24)$$

其中，各符号解释如下：

1. x 为观测变量。
2. 该模型共由 k 个高斯模型混合组成， $\phi(x|\mu_i, \sigma_i^2) = \frac{1}{\sqrt{2\pi}\sigma_i} e^{-\frac{(x-\mu_i)^2}{2\sigma_i^2}}$ 为高斯模型的概率密度函数。
3. α_i 为对应的“混合系数”，随变量 x 由哪个高斯模型生成的先验分布，满足的约束为 $\alpha_i > 0, \sum_{i=1}^k \alpha_i = 1$ 。

1.2. 假设的生成过程

注意：此过程为我们假设的数据生成过程，基于一定的假设，便于后续的推导。

假设样本的生成过程由高斯混合模型生成：

1. 根据定义的先验分布 $\alpha_1, \alpha_2, \dots, \alpha_k$ 选择高斯混合成分（即某个高斯混合模型），其中，对任意一个随机变量 x ， α_i 为选择第 i 个混合成分的概率。
2. 根据被选择的高斯分布的概率密度函数进行采样，从而生成相应的样本。
3. 重复上述步骤，生成训练集 $D = \{x_1, x_2, \dots, x_m\}$ 。

总结：该过程生成了若干数据，数据来源于多个高斯模型，但是，我们不知道高斯模型的参数，也不知道每个数据来自于哪个高斯模型。而我们要做的，便是解决上述两个“不知道”。

1.3. 求后验分布

该步的目标是解决第二个“不知道”：数据来自于哪个高斯模型。

假设目前已经给定数据集 $D = \{x_1, x_2, \dots, x_m\}$ ，令随机变量 $z_j \in \{1, 2, \dots, k\}$ 表示样本 x_j 由哪个高斯模型生成，其取值未知。基于假设， z_j 的先验概率为：

$$P(z_j = i) = \alpha_i, \quad i \in \{1, 2, \dots, k\} \quad (25)$$

根据贝叶斯定理, z_j 的后验分布为:

$$\begin{aligned} P_M(z_j = i | x_j) &= \frac{P(z_j = i) P_M(x_j | z_j = i)}{P_M(x_j)} \\ &= \frac{\alpha_i \cdot \phi(x_j | \mu_i, \sigma_i^2)}{\sum_{l=1}^k \alpha_l \cdot \phi(x_j | \mu_l, \sigma_l^2)} \end{aligned} \quad (26)$$

换言之, $P_M(z_j = i | x_j)$ 给出了样本 x_j 由第 i 个高斯模型生成的后验概率分布, 简记为 γ_{ji} ($i = 1, 2, \dots, k$).

由全概率公式可得:

$$\sum_{i=1}^k P_M(z_j = i | x_j) = \sum_{i=1}^k \gamma_{ji} = 1 \quad (27)$$

1.4. 聚类

当高斯混合模型 (公式一) 已知时, 高斯混合聚类将把样本集 D 划分为 k 个簇 $C = \{C_1, C_2, \dots, C_k\}$. 每个样本由一个高斯分布生成, 来自于同一个高斯分布的样本被认为一类, 每个样本 x_j 的簇标记 λ_j 如下确定:

$$\underset{i \in \{1, 2, \dots, k\}}{\operatorname{argmax}} \gamma_{ji} \quad (28)$$

因此, 从原型聚类的角度来看, 高斯混合聚类时采用概率模型 (高斯分布) 对原型进行刻画, 簇划分则由原型对应的后验概率确定。

2. 参数求解

2.1. 极大似然估计

给定样本集 D , 样本个数为 m , 可使用极大似然法对模型参数 $\{(\alpha_i, \mu_i, \sigma_i^2) | 1 \leq i \leq k\}$ 进行估计。对数似然函数为:

$$\begin{aligned} LL(D) &= \ln \left(\prod_{j=1}^m P_M(x_j) \right) \\ &= \sum_{j=1}^m \ln (P_M(x_j)) \\ &= \sum_{j=1}^m \ln \left(\sum_{l=1}^k \alpha_l \cdot \phi(x_j | \mu_l, \sigma_l^2) \right) \\ &= \sum_{j=1}^m \ln \left(\sum_{l=1}^k \alpha_l \cdot \frac{1}{\sqrt{2\pi}\sigma_l} e^{-\frac{(x_j - \mu_l)^2}{2\sigma_l^2}} \right) \end{aligned} \quad (29)$$

2.1.1. 求 μ_i

令 $\frac{\partial LL(D)}{\partial \mu_i} = 0$, 则:

$$\begin{aligned} \frac{\partial LL(D)}{\partial \mu_i} &= \frac{\partial \sum_{j=1}^m \ln \left(\sum_{l=1}^k \alpha_l \cdot \frac{1}{\sqrt{2\pi}\sigma_l} e^{-\frac{(x_j - \mu_l)^2}{2\sigma_l^2}} \right)}{\partial \mu_i} \\ &= \sum_{j=1}^m \frac{\alpha_i \cdot \frac{1}{\sqrt{2\pi}\sigma_i} \cdot 2(x_j - \mu_i) \cdot e^{-\frac{(x_j - \mu_i)^2}{2\sigma_i^2}}}{\sum_{l=1}^k \alpha_l \cdot \phi(x_j | \mu_l, \sigma_l)} \\ &= \sum_{j=1}^m \frac{\alpha_i \cdot 2(x_j - \mu_i) \cdot \phi(x_j | \mu_i, \sigma_i)}{\sum_{l=1}^k \alpha_l \cdot \phi(x_j | \mu_l, \sigma_l)} \end{aligned} \quad (30)$$

$$\begin{aligned}
&= 2 \sum_{j=1}^m \gamma_{ji} \cdot (x_j - \mu_i) \\
&= 2 \sum_{j=1}^m \gamma_{ji} x_j - 2 \sum_{j=1}^m \gamma_{ji} \mu_i \\
&= 0
\end{aligned}$$

求解可得：

$$\mu_i = \frac{\sum_{j=1}^m \gamma_{ji} x_j}{\sum_{j=1}^m \gamma_{ji}} \quad (31)$$

2.1.2. 求 σ_i

令 $\frac{\partial LL(D)}{\partial \sigma_i} = 0$, 则：

$$\begin{aligned}
\frac{\partial LL(D)}{\partial \sigma_i} &= \frac{\partial \sum_{j=1}^m \ln \left(\sum_{l=1}^k \alpha_l \cdot \frac{1}{\sqrt{2\pi}\sigma_l} e^{-\frac{(x_j - \mu_l)^2}{2\sigma_l^2}} \right)}{\partial \sigma_i} \\
&= \sum_{j=1}^m \frac{\alpha_i \cdot \frac{1}{\sqrt{2\pi}} \left[-1 \cdot \frac{1}{\sigma_i^2} \cdot e^{-\frac{(x_j - \mu_i)^2}{2\sigma_i^2}} + \frac{1}{\sigma_i} \cdot (x_j - \mu_i)^2 \cdot \frac{1}{\sigma_i^3} \cdot e^{-\frac{(x_j - \mu_i)^2}{2\sigma_i^2}} \right]}{\sum_{l=1}^k \alpha_l \cdot \phi(x_j | \mu_l, \sigma_l)} \quad (32) \\
&= \sum_{j=1}^m \frac{\alpha_i \cdot \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{(x_j - \mu_i)^2}{2\sigma_i^2}} \cdot \left[\frac{-1}{\sigma_i^2} + \frac{1}{\sigma_i^4} (x_j - \mu_i)^2 \right]}{\sum_{l=1}^k \alpha_l \cdot \phi(x_j | \mu_l, \sigma_l)} \\
&= \sum_{j=1}^m \alpha_i \cdot \frac{1}{\sqrt{2\pi}} \cdot \gamma_{ji} \cdot \frac{(x_j - \mu_i)^2 - \sigma_i^2}{\sigma_i^4} \\
&= 0
\end{aligned}$$

求解可得：

$$\sigma_i^2 = \frac{\sum_{j=1}^m \gamma_{ji} (x_j - \mu_i)^2}{\sum_{j=1}^m \gamma_{ji}} \quad (33)$$

2.1.3. 求 α_i

对于混合系数 α_i , 除了要最大化 $LL(D)$, 还需要满足 $\alpha_i > 0$, $\sum_{i=0}^k \alpha_i = 1$, 构造如下拉格朗日函数：

$$\mathcal{L} = LL(D) + \lambda \left(\sum_{l=1}^k \alpha_l - 1 \right) \quad (34)$$

其中, λ 为拉格朗日乘子

对 α_i 求导可得：

$$\begin{aligned}
\frac{\partial \mathcal{L}}{\partial \alpha_i} &= \frac{\partial \left\{ \sum_{j=1}^m \ln \left(\sum_{l=1}^k \alpha_l \cdot \frac{1}{\sqrt{2\pi}\sigma_l} e^{-\frac{(x_j - \mu_l)^2}{2\sigma_l^2}} \right) + \lambda \left(\sum_{l=1}^k \alpha_l - 1 \right) \right\}}{\partial \alpha_i} \\
&= \sum_{j=1}^m \frac{\frac{1}{\sqrt{2\pi}\sigma_i} e^{-\frac{(x_j - \mu_i)^2}{2\sigma_i^2}}}{\sum_{l=1}^k \alpha_l \cdot \phi(x_j | \mu_l, \sigma_l^2)} + \lambda \quad (35)
\end{aligned}$$

$$\begin{aligned}
&= \sum_{j=1}^m \frac{\sum_{l=1}^k \alpha_l \cdot \phi(x_j | \mu_l, \sigma_l^2)}{\sum_{l=1}^k \alpha_l \cdot \phi(x_j | \mu_l, \sigma_l^2)} + \lambda \\
&= 0
\end{aligned}$$

两边同乘以 α_i 可得：

$$\begin{aligned}
&\sum_{j=1}^m \frac{\alpha_i \cdot \phi(x_j | \mu_i, \sigma_i^2)}{\sum_{l=1}^k \alpha_l \cdot \phi(x_j | \mu_l, \sigma_l^2)} + \alpha_i \lambda = 0 \\
&\Rightarrow \sum_{j=1}^m \gamma_{ji} + \alpha_i \lambda = 0 \\
&\Rightarrow \sum_{l=1}^k \sum_{j=1}^m \gamma_{ji} + \sum_{l=1}^k \alpha_i \lambda = 0 \\
&\Rightarrow \sum_{j=1}^m \sum_{l=1}^k \gamma_{ji} + \lambda = 0 \\
&\Rightarrow m + \lambda = 0 \\
&\Rightarrow \lambda = -m
\end{aligned} \tag{36}$$

将 λ 带入可得： $\sum_{j=1}^m \gamma_{ji} - \alpha_i m = 0$

求解可得：

$$\alpha_i = \frac{1}{m} \sum_{j=1}^m \gamma_{ji} \tag{37}$$

2.1.4. 迭代过程

1. 先根据当前参数计算每个样本属于每个高斯模型的后验概率 γ_{ji}
2. 根据参数公式对参数进行更新

2.2. EM算法

2.2.1. 完全数据的对数似然函数

首先需要明确**隐变量**，写出完全数据的对数似然函数。

定义隐变量如下：

$$\gamma_{jk} = \begin{cases} 1, & \text{第 } j \text{ 个观测来自第 } k \text{ 个分模型} \\ 0, & \text{否则} \end{cases} \tag{38}$$

那么，完全数据为： $(x_j, \gamma_{j1}, \gamma_{j2}, \dots, \gamma_{jk}), \quad j = 1, 2, \dots, m$

令 $\theta = (\mu, \sigma^2)$ ，则**完全数据的似然函数**为：

$$\begin{aligned}
P(x, \gamma \mid \alpha, \theta) &= \prod_{j=1}^m P(x_j, \gamma_{j1}, \gamma_{j2}, \dots, \gamma_{jk} \mid \alpha, \theta) \\
&= \prod_{j=1}^m \prod_{l=1}^k [\alpha_l \phi(x_j \mid \theta_l)]^{\gamma_{jl}} \\
&= \prod_{l=1}^k \prod_{j=1}^m [\alpha_l \phi(x_j \mid \theta_l)]^{\gamma_{jl}} \\
&= \prod_{l=1}^k \alpha_l^{\sum_{j=1}^m \gamma_{jl}} \prod_{j=1}^m [\phi(x_j \mid \theta_l)]^{\gamma_{jl}} \\
&= \prod_{l=1}^k \alpha_l^{\sum_{j=1}^m \gamma_{jl}} \prod_{j=1}^m \left[\frac{1}{\sigma} \exp \left(-\frac{(x_j - \mu_l)^2}{2\sigma^2} \right) \right]^{\gamma_{jl}}
\end{aligned} \tag{39}$$

$$\prod_{l=1}^k \left[\sqrt{2\pi\sigma_l} \exp\left(-\frac{x_j - \mu_l}{2\sigma_l^2}\right) \right]^{\gamma_{jl}}$$

上述公式解释：

$$1. P(x_j, \gamma_{j1}, \gamma_{j2}, \dots, \gamma_{jk} | \alpha, \theta)$$

表示在参数 θ 下选择某个高斯模型(假设第 s 个)生成数据 x_j 的概率，则根据先验知识，该过程分为两个步骤：

- 依概率 α_s 选择第 s 个高斯模型
- 通过 $\phi(x|\theta_s)$ 生成 x_j

所以，综合来看，如果不知道 x_j 由哪个模型生成，则该概率为：

$$P(x_j, \gamma_{j1}, \gamma_{j2}, \dots, \gamma_{jk} | \alpha, \theta) = \prod_{l=1}^k [\alpha_l \cdot \phi(x_j | \theta)]^{\gamma_{jl}} \quad (40)$$

由哪个模型生成，则对应的 λ 为1。

$$2. P(x_j, \gamma_{j1}, \gamma_{j2}, \dots, \gamma_{jk} | \alpha, \theta) \text{与} P(x_j) \text{的区别}$$

$P(x_j) = \sum_{i=1}^k \alpha_i \cdot \phi(x_j | \mu_i, \sigma_i^2)$ 需要考虑 x_j 可能来源于 k 个高斯模型中的任何一个，而 $P(x_j, \gamma_{j1}, \gamma_{j2}, \dots, \gamma_{jk} | \alpha, \theta)$ 则限定了 x_j 只会来源于某一个高斯模型。

$$3. \sum_{l=1}^k \sum_{j=1}^m \gamma_{jl} = 1$$

完全数据的对数似然函数为：

$$\begin{aligned} \ln P(x, \gamma | \alpha, \theta) &= \ln \left\{ \prod_{l=1}^k \alpha_l^{\sum_{j=1}^m \gamma_{jl}} \prod_{j=1}^m \left[\frac{1}{\sqrt{2\pi}\sigma_l} \exp\left(-\frac{(x_j - \mu_l)^2}{2\sigma_l^2}\right) \right]^{\gamma_{jl}} \right\} \\ &= \sum_{l=1}^k \left\{ \sum_{j=1}^m \gamma_{jl} \cdot \ln \alpha_l + \sum_{j=1}^m \gamma_{jl} \left[\ln \frac{1}{\sqrt{2\pi}} - \ln \sigma_l - \frac{(x_j - \mu_l)^2}{2\sigma_l^2} \right] \right\} \end{aligned} \quad (41)$$

此似然函数中包含隐变量 γ_{jl} ，因此，不能够直接最大化似然函数。反之，如果知道了 γ_{jl} ，则最大化似然函数水到渠成。

怎么办呢？基于当前的模型参数 (α, θ) ，先对隐变量 γ_{jl} 进行当下的估计。

初始化的时候可以随机给定 $(\alpha^{(0)}, \theta^{(0)})$ ，也就是当前知道了每个高斯分布的参数，而隐变量 γ 则是指明数据由哪个高斯模型产生，有了每个高斯模型的参数，自然就能够计算数据最可能来自哪个高斯模型，也就知道了隐变量 γ 。将上述步骤迭代进行之，则是EM算法。

2.2.2. E步：确定Q函数

$$\begin{aligned} Q(\theta, \alpha^{(i)}, \theta^{(i)}) &= E \left[\log P(x, \gamma | \alpha, \theta) | x, \alpha^{(i)}, \theta^{(i)} \right] \\ &= E \left\{ \sum_{l=1}^k \left\{ \left(\sum_{j=1}^m \gamma_{jl} | x_j, \alpha^{(i)}, \theta^{(i)} \right) \cdot \ln \alpha_l + \left(\sum_{j=1}^m \gamma_{jl} | x_j, \alpha^{(i)}, \theta^{(i)} \right) \left[\ln \frac{1}{\sqrt{2\pi}} - \ln \sigma_l - \frac{(x_j - \mu_l)^2}{2\sigma_l^2} \right] \right\} \right\} \\ &= \sum_{l=1}^k \left\{ \left(\sum_{j=1}^m E(\gamma_{jl} | x_j, \alpha^{(i)}, \theta^{(i)}) \right) \ln \alpha_l + \left(\sum_{j=1}^m E(\gamma_{jl} | x_j, \alpha^{(i)}, \theta^{(i)}) \right) \left[\ln \left(\frac{1}{\sqrt{2\pi}} \right) - \log \sigma_l - \frac{1}{2\sigma_l^2} (x_j - \mu_l)^2 \right] \right\} \end{aligned} \quad (42)$$

其中， $E(\gamma_{jl} | x_j, \alpha^{(i)}, \theta^{(i)})$ 则是基于当前参数对隐变量 γ_{jl} 的估计：

$$\begin{aligned} E(\gamma_{jl} | x_j, \alpha^{(i)}, \theta^{(i)}) &= P(\gamma_{jl} = 1 | x_j, \alpha^{(i)}, \theta^{(i)}) \\ &= \frac{P(\gamma_{jl} = 1, x_j | \alpha^{(i)}, \theta^{(i)})}{\sum_{t=1}^k P(\gamma_{jt} = 1, x_j | \alpha^{(i)}, \theta^{(i)})} \\ &= \frac{P(\gamma_{jl} = 1 | \alpha^{(i)}, \theta^{(i)}) \cdot P(x_j | \gamma_{jl} = 1, \alpha^{(i)}, \theta^{(i)})}{\sum_{t=1}^k P(x_j | \gamma_{jt} = 1, \alpha^{(i)}, \theta^{(i)}) P(\gamma_{jt} = 1 | \alpha^{(i)}, \theta^{(i)})} \\ &= \frac{\alpha_l^{(i)} \cdot \phi(x_j | \theta_l^{(i)})}{\sum_{t=1}^k \alpha_t^{(i)} \cdot \phi(x_j | \theta_t^{(i)})} \\ &= \hat{\gamma}_{jl}^{(i)}, \quad j = 1, 2, \dots, m; \quad l = 1, 2, \dots, k \end{aligned} \quad (43)$$

将 $E(\gamma_{jl} \mid x_j, \alpha^{(i)}, \theta^{(i)})$ 带回 Q 函数可得：

$$Q(\theta, \alpha^{(i)}, \theta^{(i)}) = \sum_{l=1}^k \left\{ \left(\sum_{j=1}^m \hat{\gamma}_{jl}^{(i)} \right) \ln \alpha_l + \left(\sum_{j=1}^m \hat{\gamma}_{jl}^{(i)} \right) \left[\ln \left(\frac{1}{\sqrt{2\pi}} \right) - \log \sigma_l - \frac{1}{2\sigma_l^2} (x_j - \mu_l)^2 \right] \right\} \quad (44)$$

2.2.3. M步：Q函数最大化

有了 Q 函数，就可以对 Q 函数进行最大化，得到下一次迭代的模型参数了，即：

$$\alpha^{(i+1)}, \theta^{(i+1)} = \arg \max_{\theta} Q(\theta, \alpha^{(i)}, \theta^{(i)}) \quad (45)$$

采用求导及拉格朗日乘法，可得第 $i+1$ 轮参数为：

$$\begin{aligned} \hat{\mu}_l &= \frac{\sum_{j=1}^m \hat{\gamma}_{jl}^{(i)} x_j}{\sum_{j=1}^m \hat{\gamma}_{jl}^{(i)}} \\ \hat{\sigma}_l^2 &= \frac{\sum_{j=1}^m \hat{\gamma}_{jl}^{(i)} (x_j - \mu_l^{(i)})^2}{\sum_{j=1}^N \hat{\gamma}_{jl}^{(i)}} \\ \hat{\alpha}_l &= \frac{\sum_{j=1}^m \hat{\gamma}_{jl}^{(i)}}{m} \end{aligned} \quad (46)$$

其中， $l = 1, 2, \dots, k$

3. 例子

见《西瓜书》P210页。

4. 参考文档

1. [\(48条消息\) 详解EM算法与混合高斯模型\(Gaussian mixture model, GMM\)林立民爱洗澡-CSDN博客混合高斯模型](#)
2. 《西瓜书》P206