

隐马尔可夫模型

2021-08-20

1. 隐马尔可夫模型

- 1.1. 模型简介
- 1.2. 模型定义
- 1.3. 两个基本假设
- 1.4. 三个基本问题

2. 概率计算问题

- 2.1. 直接计算
- 2.2. 前向计算
- 2.3. 后向计算
- 2.4. 若干公式

3. 学习问题

- 3.1. 状态已知，观测已知
- 3.2. 状态未知，观测已知
 - 3.2.1. 问题定义
 - 3.2.2. 完全数据的对数似然
 - 3.2.3. E步：求Q函数
 - 3.2.4. M步：极大化Q函数

4. 预测问题

- 4.1. 贪心算法
- 4.2. 维特比算法


5. 例题：盒子和球模型

6. 参考文档

1. 隐马尔可夫模型

1.1. 模型简介

隐马尔可夫模型（Hidden Markov Model, HMM）是关于时序的概率模型，描述由一个隐藏的马尔可夫链随机生成不可观测的状态随机序列，再由各个状态生成一个观测而产生观测随机序列的过程。隐藏的马尔可夫链随机生成的状态的序列，称为状态序列；每个状态生成一个观测，由此产生的随机序列称为观测序列。序列的每一个位置又可以看作是一个时刻。



1.2. 模型定义

模型定义如下：

1. 状态集合 Q ，包含 N 种可能， $Q = \{q_1, q_2, \dots, q_N\}$
2. 观测集合 V ，包含 M 种可能， $V = \{v_1, v_2, \dots, v_M\}$
3. 状态序列 I ，长度为 T ， $I = \{i_1, i_2, \dots, i_T\}$
4. 观测序列 O ，长度为 T ， $O = \{o_1, o_2, \dots, o_T\}$
5. 状态转移概率矩阵 A ， $A = [a_{ij}]_{N \times N}$ ，其中， $a_{ij} = P(i_{t+1} = q_j | i_t = q_i)$ ， $i = 1, 2, \dots, N; j = 1, 2, \dots, N$
6. 观测概率矩阵 B ， $B = [b_{jk}]_{N \times M}$ ，其中， $b_{jk} = P(o_t = v_k | i_t = q_j)$ ， $j = 1, 2, \dots, N; k = 1, 2, \dots, M$
7. 初始状态概率向量 π ， $\pi = (\pi_1, \pi_2, \dots, \pi_N)$ ，其中， $\pi_i = P(i_1 = q_i)$ ， $i = 1, 2, \dots, N$


隐马尔可夫模型由初始状态向量 π 、状态转移概率矩阵 A 和观测概率矩阵 B 决定。 π 和 A 决定状态序列， B 决定观测序列。因此，隐马尔可夫模型 λ 可以用三元符号表示，即： $\lambda = (A, B, \pi)$ 。

1.3. 两个基本假设

1. 齐次马尔可夫性假设

假设隐藏的马尔可夫链在任意时刻 t 的状态只依赖于其前一时刻的状态，与其它时刻的状态及观测无关，也与时刻 t 无关：


$$P(i_t | i_{t-1}, o_{t-1}, \dots, i_1, o_1) = P(i_t | i_{t-1}) \quad (52)$$



2. 观测独立性假设

假设任意时刻的观测只依赖于该时刻马尔可夫链的状态，与其它观测及状态无关：

$$P(o_t | i_T, o_T, i_{T-1}, o_{T-1}, \dots, i_t, i_{t-1}, o_{t-1}, \dots, i_1, o_1) = P(o_t | i_t) \quad (53)$$



1.4. 三个基本问题

1. 概率计算问题

给定模型 $\lambda = (A, B, \pi)$ 和观测序列 $O = (o_1, o_2, \dots, o_T)$ ，计算在模型 λ 下观测序列 O 出现的概率 $P(O | \lambda)$ 。

2. 学习问题

已知观测序列 $O = (o_1, o_2, \dots, o_T)$ ，估计模型的 $\lambda = (A, B, \pi)$ 参数，使得在该模型下观测序列概率 $P(O | \lambda)$ 最大。

3. 预测问题

已知模型参数 $\lambda = (A, B, \pi)$ 和观测序列 $O = (o_1, o_2, \dots, o_T)$ ，求最有可能的状态序列 $I = (i_1, i_2, \dots, i_T)$ ，即使得 $P(I | O, \lambda)$ 最大。

2. 概率计算问题

2.1. 直接计算

$$\begin{aligned} P(O | \lambda) &= \sum_I P(O, I | \lambda) \\ &= \sum_I P(O | I, \lambda) P(I | \lambda) \end{aligned} \quad (54)$$

其中， $P(I | \lambda)$ 表示给定模型参数时，产生状态序列 $I = (i_1, i_2, \dots, i_T)$ 的概率：

$$P(I | \lambda) = \pi_{i_1} a_{i_1 i_2} a_{i_2 i_3} \cdots a_{i_{T-1} i_T} \quad (55)$$

$P(O | I, \lambda)$ 表示给定模型参数 λ 且状态序列为 $I = (i_1, i_2, \dots, i_T)$ ，产生观测序列 $O = (o_1, o_2, \dots, o_T)$ 的概率：

$$P(O | I, \lambda) = b_{i_1 o_1} b_{i_2 o_2} \cdots b_{i_T o_T} \quad (56)$$

因此：

$$\begin{aligned} P(O | \lambda) &= \sum_I P(O, I | \lambda) \\ &= \sum_I P(O | I, \lambda) P(I | \lambda) \\ &= \sum_{i_1, i_2, \dots, i_T} \pi_{i_1} b_{i_1 o_1} a_{i_1 i_2} b_{i_2 o_2} \cdots a_{i_{T-1} i_T} b_{i_T o_T} \end{aligned} \quad (57)$$

接下来，对该式进行算法复杂度分析：


1. $\sum_{i_1, i_2, \dots, i_T}$ 共有 N^T 种可能，故时间复杂度为 $O(N^T)$
2. $\pi_{i_1} b_{i_1 o_1} a_{i_1 i_2} b_{i_2 o_2} \cdots a_{i_{T-1} i_T} b_{i_T o_T}$ 时间复杂度为 $O(T)$

由上述分析，该式总的时间复杂度为 $O(TN^T)$ ，指数级复杂度，实际中不可行。

2.2. 前向计算

首先定义前向概率：给定隐马尔可夫模型 λ ，定义到时刻 t 时部分观测序列为 (o_1, o_2, \dots, o_t) 且状态为 q_i 的概率为**前向概率**，记作：

$$\alpha_t(i) = P(o_1, o_2, \dots, o_t, i_t = q_i \mid \lambda) \quad (58)$$



对前向概率推导得：

$$\begin{aligned} \alpha_t(i) &= P(o_1, o_2, \dots, o_t, i_t = q_i \mid \lambda) \\ &= P(i_t = q_i, o_1^t) \\ &= \sum_{j=1}^N P(i_{t-1} = q_j, i_t = q_i, o_1^{t-1}, o_t) \\ &= \sum_{j=1}^N P(i_t = q_i, o_t \mid i_{t-1} = q_j, o_1^{t-1}) \cdot P(i_{t-1} = q_j, o_1^{t-1}) \\ &= \sum_{j=1}^N P(i_t = q_i, o_t \mid i_{t-1} = q_j) \cdot \alpha_{t-1}(j) \\ &= \sum_{j=1}^N P(o_t \mid i_t = q_i, i_{t-1} = q_j) \cdot P(i_t = q_i \mid i_{t-1} = q_j) \cdot \alpha_{t-1}(j) \\ &= \sum_{j=1}^N P(o_t \mid i_t = q_i) \cdot P(i_t = q_i \mid i_{t-1} = q_j) \cdot \alpha_{t-1}(j) \\ &= \sum_{j=1}^N b_{io_t} \cdot a_{ji} \cdot \alpha_{t-1}(j) \\ &= \sum_{j=1}^N [a_{ji} \cdot \alpha_{t-1}(j)] \cdot b_{io_t} \end{aligned} \quad (59)$$

其中， $i = (1, 2, \dots, N), t = (2, 3, \dots, T)$

公式说明：因所有概率均在参数 λ 下计算，故从第二步开始，省略条件中的 λ

因此，

$$\alpha_T(i) = \left[\sum_{j=1}^N \alpha_{T-1}(j) a_{ji} \right] \times b_{io_T} \quad (60)$$

基于前向概率，可得**观测序列的概率**为：

$$P(O \mid \lambda) = P(o_1, o_2, \dots, o_T \mid \lambda) = \sum_{i=1}^N P(o_1, o_2, \dots, o_T, i_T = q_i \mid \lambda) = \sum_{i=1}^N \alpha_T(i) \quad (61)$$

根据上述推导，可得通过前向算法计算观测概率的算法如下：

算法 1.0 (观测序列概率的前向算法)

输入：隐马尔可夫模型 λ ，观测序列 O

输出：观测序列概率 $P(O \mid \lambda)$

- 初值： $\alpha_1(i) = P(o_1, i_1 = q_i \mid \lambda) = P(o_1 \mid i_1 = q_i, \lambda) \cdot P(i_1 = q_i \mid \lambda) = \pi_i \cdot b_{io_1}, i = 1, 2, \dots, N$
- 递推： $\alpha_t(i) = \sum_{j=1}^N [a_{ji} \cdot \alpha_{t-1}(j)] \cdot b_{io_t}, i = 1, 2, \dots, N, t = 2, 3, \dots, T$
- 终止： $P(O \mid \lambda) = \sum_{i=1}^N \alpha_T(i)$

时间复杂度分析：

1. 根据递推公式，需要遍历 $\sum_{i=1}^N \sum_{j=1}^N$ ，所以时间复杂度为 $O(N^2)$


2. 时间维度的计算，时间复杂度是 $O(T)$

由上述分析可以，总的时间复杂度为 $O(TN^2)$ ，相比直接计算，有很大提升。

2.3. 后向计算

首先定义后向概率：给定隐马尔可夫模型 λ ，定义在时刻 t 状态为 q_i 的条件下，从 $t+1$ 到 T 时刻的观测序列为 $(o_{t+1}, o_{t+2}, \dots, o_T)$ 的概率为**后向概率**，记作：

$$\beta_t(i) = P(o_{t+1}, o_{t+2}, \dots, o_T | i_t = q_i, \lambda) \quad (62)$$



对后向概率推导得：

$$\begin{aligned} \beta_t(i) &= P(o_{t+1}, o_{t+2}, \dots, o_T | i_t = q_i, \lambda) \\ &= \sum_{j=1}^N P(o_{t+1}, o_{t+2}, \dots, o_T, i_{t+1} = q_j | i_t = q_i, \lambda) \\ &= \sum_{j=1}^N P(o_{t+2}^T, o_{t+1}, i_{t+1} = q_j | i_t = q_i, \lambda) \\ &= \sum_{j=1}^N P(o_{t+2}^T | i_t = q_i, \lambda, o_{t+1}, i_{t+1} = q_j) \cdot P(o_{t+1}, i_{t+1} = q_j | i_t = q_i, \lambda) \\ &= \sum_{j=1}^N P(o_{t+2}^T | \lambda, i_{t+1} = q_j) \cdot P(o_{t+1} | i_{t+1} = q_j, i_t = q_i, \lambda) \cdot P(i_{t+1} = q_j | i_t = q_i, \lambda) \\ &= \sum_{j=1}^N \beta_{t+1}(j) \cdot b_{jo_{t+1}} \cdot a_{ij} \end{aligned} \quad (63)$$

其中， $i = (1, 2, \dots, N), t = (1, 2, \dots, T-1)$

为了确保递推公式的连贯性，令 $\beta_T(i) = P(\emptyset | i_T = q_i, \lambda) = 1$ 。

基于后向概率，可得**观测序列的概率**为：

$$P(O | \lambda) = P(o_1, o_2, \dots, o_T | \lambda) = \sum_{i=1}^N P(o_1, i_1 = q_i | \lambda) P(o_2, o_3, \dots, o_T | i_1 = q_i, \lambda) = \sum_{i=1}^N \pi_i b_{io_1} \beta_1(i) \quad (64)$$

根据上述推导，可得通过后向算法计算观测概率的算法如下：

算法 1.1 (观测序列概率的后向算法)

输入：隐马尔可夫模型 λ ，观测序列 O

输出：观测序列概率 $P(O | \lambda)$

- 初值： $\beta_T(i) = 1, i = 1, 2, \dots, N$
- 递推： $\beta_t(i) = \sum_{j=1}^N \beta_{t+1}(j) \cdot b_{jo_{t+1}} \cdot a_{ij}$ 其中， $i = (1, 2, \dots, N), t = (T-1, T-2, \dots, 1)$
- 终止： $P(O | \lambda) = \sum_{i=1}^N \pi_i b_{io_1} \beta_1(i)$

2.4. 若干公式

1. 前向概率 \times 后向概率

$$\begin{aligned} \alpha_t(i) \beta_t(i) &= P(o_1, o_2, \dots, o_t, i_t = q_i | \lambda) P(o_{t+1}, o_{t+2}, \dots, o_T | i_t = q_i, \lambda) \\ &= P(o_1^t, i_t = q_i | \lambda) \cdot P(o_{t+1}^T | i_t = q_i, \lambda) \\ &= P(o_1^t | i_t = q_i, \lambda) \cdot P(i_t = q_i | \lambda) \cdot P(o_{t+1}^T | i_t = q_i, \lambda) \\ &= P(o_1^T | i_t = q_i, \lambda) \cdot P(i_t = q_i | \lambda) \\ &= P(i_t = q_i | \lambda) \cdot P(o_1^T | i_t = q_i, \lambda) \end{aligned} \quad (65)$$

$$= r(i_t = q_i, O | \lambda)$$

2. 给定 λ 和 O ，在时刻 t 处于状态 q_i 的概率

$$\begin{aligned}\gamma_t(i) &= P(i_t = q_i | O, \lambda) \\ &= \frac{P(i_t = q_i, O | \lambda)}{P(O | \lambda)} \\ &= \frac{P(i_t = q_i, O | \lambda)}{\sum_{j=1}^N P(i_t = q_j, O | \lambda)} \\ &= \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^N \alpha_t(j)\beta_t(j)}\end{aligned}\quad (66)$$

3. 给定 λ 和 O ，在时刻 t 处于状态 q_i 且在时刻 $t+1$ 处于状态 q_j 的概率

$$\begin{aligned}\xi_t(i, j) &= P(i_t = q_i, i_{t+1} = q_j | O, \lambda) \\ &= \frac{P(i_t = q_i, i_{t+1} = q_j, O | \lambda)}{P(O | \lambda)} \\ &= \frac{P(i_t = q_i, i_{t+1} = q_j, O | \lambda)}{\sum_{i=1}^N \sum_{j=1}^N P(i_t = q_i, i_{t+1} = q_j, O | \lambda)}\end{aligned}\quad (67)$$

又因为：

$$\begin{aligned}P(i_t = q_i, i_{t+1} = q_j, O | \lambda) &= P(i_t = q_i, i_{t+1} = q_j, o_1, o_2, \dots, o_T | \lambda) \\ &= P(i_t = q_i, i_{t+1} = q_j, o_1^t, o_{t+1}^N | \lambda) \\ &= P(i_t = q_i, o_1^t | \lambda) P(i_{t+1} = q_j, o_{t+1}^N | \lambda, i_t = q_i, o_1^t) \\ &= P(i_t = q_i, o_1^t | \lambda) P(i_{t+1} = q_j, o_{t+1}^N | \lambda, i_t = q_i) \\ &= P(i_t = q_i, o_1^t | \lambda) P(i_{t+1} = q_j, o_{t+1}, o_{t+2}^N | \lambda, i_t = q_i) \\ &= P(i_t = q_i, o_1^t | \lambda) P(o_{t+2}^N | i_{t+1} = q_j, o_{t+1}, \lambda, i_t = q_i) P(i_{t+1} = q_j, o_{t+1} | \lambda, i_t = q_i) \\ &= P(i_t = q_i, o_1^t | \lambda) P(i_{t+1} = q_j, o_{t+1} | \lambda, i_t = q_i) P(o_{t+2}^N | i_{t+1} = q_j, \lambda) \\ &= \alpha_t(i) a_{ij} b_{jo_{t+1}} \beta_{t+1}(j)\end{aligned}\quad (68)$$

所以：

$$\xi_t(i, j) = \frac{\alpha_t(i) a_{ij} b_{jo_{t+1}} \beta_{t+1}(j)}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} b_{jo_{t+1}} \beta_{t+1}(j)}\quad (69)$$

3. 学习问题

3.1. 状态已知，观测已知

假设已给出训练数据包含 S 个长度相同的观测序列和对应的状态序列 $\{(O_1, I_1), (O_2, I_2) \cdots (O_S, I_S)\}$ ，那么可以利用极大似然估计法来估计隐马尔可夫模型的参数，具体方法如下：

1. 转移概率 a_{ij} 的估计

$$a_{ij} = \frac{A_{ij}}{\sum_{j=1}^N A_{ij}}\quad (94)$$

其中， A_{ij} 为样本中时刻 t 处于状态 q_i 而到时刻 $t+1$ 转移到状态 q_j 的频数。

2. 观测概率 b_{jk} 的估计

$$b_{jk} = \frac{B_{jk}}{\sum_{k=1}^M B_{jk}}\quad (95)$$

其中， B_{jk} 为样本中状态为 q_j ，对应观测为 v_k 的频数。

3. 初始状态概率 π_i 的估计

S 个样本中初始状态为 q_i 的频率。

3.2. 状态未知，观测已知

3.2.1. 问题定义

仅知道观测序列为 $O = (o_1, o_2, \dots, o_T)$ ，而不知道状态序列数据 $I = (i_1, i_2, \dots, i_T)$ ，那么隐马尔可夫模型就是一个含有隐变量的概率模型：

$$P(O | \lambda) = \sum_I P(O | I, \lambda) P(I | \lambda)\quad (70)$$

可使用EM算法对该问题进行参数求解，该算法亦称为Baum-Welch算法。

3.2.2. 完全数据的对数似然

需要确定完全数据的对数似然函数。

观测数据为 $O = (o_1, o_2, \dots, o_T)$ ，未观测数据为 $I = (i_1, i_2, \dots, i_T)$ ，则完全数据为 $(O, I) = (o_1, i_1, o_2, i_2, \dots, o_T, i_T)$ ，完全数据的对数似然函数为：

$$\ln P(O, I | \lambda) \quad (71)$$

其中， $P(O, I | \lambda) = \pi_{i_1} b_{i_1 o_1} a_{i_1 i_2} b_{i_2 o_2} \dots a_{i_{T-1} i_T} b_{i_T o_T}$ ，所以可进一步得到：

$$\begin{aligned} \ln P(O, I | \lambda) &= \ln (\pi_{i_1} b_{i_1 o_1} a_{i_1 i_2} b_{i_2 o_2} \dots a_{i_{T-1} i_T} b_{i_T o_T}) \\ &= \ln \pi_{i_1} + \sum_{t=1}^{T-1} \ln a_{i_t i_{t+1}} + \sum_{t=1}^T \ln b_{i_t o_t} \end{aligned} \quad (72)$$

3.2.3. E步：求Q函数

定义Q函数如下：

$$Q(\lambda, \bar{\lambda}) = \sum_I P(I | O, \bar{\lambda}) \ln \frac{P(O, I | \lambda)}{P(O | \bar{\lambda})} \quad (73)$$

其中， $\bar{\lambda}$ 是隐马尔可夫模型参数的当前估计值， λ 是要极大化的隐

为了后续计算方便，对Q函数做如下恒等变形：

$$\begin{aligned} Q(\lambda, \bar{\lambda}) &= \sum_I P(I | O, \bar{\lambda}) \ln P(O, I | \lambda) \\ &= \sum_I \frac{P(O, I | \bar{\lambda})}{P(O | \bar{\lambda})} \ln P(O, I | \lambda) \end{aligned} \quad (74)$$

由于接下来仅极大化 λ ， $P(O | \bar{\lambda})$ 作为常数项可以省略，所以Q函数可以进一步简化为：

$$\begin{aligned} Q(\lambda, \bar{\lambda}) &= \sum_I P(O, I | \bar{\lambda}) \ln P(O, I | \lambda) \\ &= \sum_I P(O, I | \bar{\lambda}) \left(\ln \pi_{i_1} + \sum_{t=1}^{T-1} \ln a_{i_t i_{t+1}} + \sum_{t=1}^T \ln b_{i_t o_t} \right) \\ &= \sum_I P(O, I | \bar{\lambda}) \ln \pi_{i_1} + \sum_I P(O, I | \bar{\lambda}) \left(\sum_{t=1}^{T-1} \ln a_{i_t i_{t+1}} \right) + \sum_I P(O, I | \bar{\lambda}) \left(\sum_{t=1}^T \ln b_{i_t o_t} \right) \end{aligned} \quad (75)$$

3.2.4. M步：极大化Q函数

由于要极大化的参数在上式中单独地出现在3个项中，所以只需对各项分别极大化。

1. 求 π_i

Q函数中的第1项可以写成：

$$\begin{aligned} \sum_I P(O, I | \bar{\lambda}) \ln \pi_{i_1} &= \sum_{i_1, i_2, \dots, i_T} P(O, i_1, i_2, \dots, i_T | \bar{\lambda}) \ln \pi_{i_1} \\ &= \sum_{i=1}^N \left(\sum_{i_2, i_3, \dots, i_T} P(O, i_1 = q_i, i_2, i_3, \dots, i_T | \bar{\lambda}) \ln \pi_i \right) \\ &= \sum_{i=1}^N \left\{ \ln \pi_i \cdot \left(\sum_{i_2, i_3, \dots, i_T} P(O, i_1 = q_i, i_2, i_3, \dots, i_T | \bar{\lambda}) \right) \right\} \\ &= \sum_{i=1}^N \ln \pi_i P(O, i_1 = q_i | \bar{\lambda}) \end{aligned} \quad (76)$$

由于 π 需要满足约束 $\sum_{i=1}^N \pi_i = 1$ ，利用拉格朗日乘法，写出拉格朗日函数：

$$\sum_{i=1}^N \ln \pi_i P(O, i_1 = q_i | \bar{\lambda}) + \eta \left(\sum_{i=1}^N \pi_i - 1 \right) \quad (77)$$

对拉格朗日函数关于 π 求偏导并令结果为0：

$$\begin{aligned} \frac{\partial}{\partial \pi_i} \left[\sum_{i=1}^N \ln \pi_i P(O, i_1 = q_i | \bar{\lambda}) + \eta \left(\sum_{i=1}^N \pi_i - 1 \right) \right] &= 0 \\ \frac{1}{\pi_i} \cdot P(O, i_1 = q_i | \bar{\lambda}) + \eta &= 0 \\ P(O, i_1 = q_i | \bar{\lambda}) + \eta \pi_i &= 0 \end{aligned} \quad (78)$$

利用 $\sum_{i=1}^N \pi_i = 1$ ，对上式两边关于 i 求和可得：

$$\begin{aligned} \sum_{i=1}^N [P(O, i_1 = q_i | \bar{\lambda}) + \eta \pi_i] &= 0 \\ \sum_{i=1}^N P(O, i_1 = q_i | \bar{\lambda}) + \sum_{i=1}^N \eta \pi_i &= 0 \end{aligned} \quad (79)$$

$$\sum_{i=1}^N \left(P(O | \bar{\lambda}) + \eta \cdot 1 = 0 \right)$$

$$\eta = -P(O | \bar{\lambda})$$

将其带回 $P(O, i_1 = q_i | \bar{\lambda}) + \eta \pi_i = 0$ 可得:

$$P(O, i_1 = q_i | \bar{\lambda}) - P(O | \bar{\lambda}) \cdot \pi_i = 0 \quad (80)$$

$$\begin{aligned} \pi_i &= \frac{P(O, i_1 = q_i | \bar{\lambda})}{P(O | \bar{\lambda})} \\ &= P(i_1 = q_i | O, \bar{\lambda}) \\ &= \gamma_1(i) \\ &= \frac{\alpha_1(i) \beta_1(i)}{\sum_{j=1}^N \alpha_1(j) \beta_1(j)} \end{aligned} \quad (81)$$

其中, $\gamma_1(i) = \frac{\alpha_1(i) \beta_1(i)}{\sum_{j=1}^N \alpha_1(j) \beta_1(j)}$ 表示给定模型参数 $\bar{\lambda}$ 和观测 O , 在时刻 t 处于状态 q_i 的概率。

2. 求 a_{ij}

Q 函数中的第2项可以写成:

$$\begin{aligned} \sum_I P(O, I | \bar{\lambda}) \left(\sum_{t=1}^{T-1} \ln a_{i_t, i_{t+1}} \right) &= \sum_{t=1}^{T-1} \left(\sum_{i_1, i_2, \dots, i_T} P(O, i_1, i_2, \dots, i_T | \bar{\lambda}) \ln a_{i_t, i_{t+1}} \right) \\ &= \sum_{t=1}^{T-1} \left\{ \sum_{i=1}^N \sum_{j=1}^N \left(\sum_{i_1, i_2, \dots, i_{t-1}, i_{t+2}, \dots, i_T} P(O, i_1, i_2, \dots, i_t = q_i, i_{t+1} = q_j, \dots, i_T | \bar{\lambda}) \ln a_{ij} \right) \right\} \\ &= \sum_{t=1}^{T-1} \left\{ \sum_{i=1}^N \sum_{j=1}^N \left[\ln a_{ij} \cdot \left(\sum_{i_1, i_2, \dots, i_{t-1}, i_{t+2}, \dots, i_T} P(O, i_1, i_2, \dots, i_t = q_i, i_{t+1} = q_j, \dots, i_T | \bar{\lambda}) \right) \right] \right\} \\ &= \sum_{t=1}^{T-1} \sum_{i=1}^N \sum_{j=1}^N \ln a_{ij} P(O, i_t = q_i, i_{t+1} = q_j | \bar{\lambda}) \end{aligned}$$

由于 a_{ij} 需要满足 $\sum_{j=1}^N a_{ij} = 1$ 的约束条件, 同样需要利用拉格朗日乘子法, 写出拉格朗日函数:

$$\sum_{t=1}^{T-1} \sum_{i=1}^N \sum_{j=1}^N \ln a_{ij} P(O, i_t = q_i, i_{t+1} = q_j | \bar{\lambda}) + \eta \left(\sum_{j=1}^N a_{ij} - 1 \right) \quad (83)$$

对拉格朗日函数关于 a_{ij} 求偏导并令结果为0:

$$\begin{aligned} \frac{\partial}{\partial a_{ij}} \left[\sum_{t=1}^{T-1} \sum_{i=1}^N \sum_{j=1}^N \ln a_{ij} P(O, i_t = q_i, i_{t+1} = q_j | \bar{\lambda}) + \eta \left(\sum_{j=1}^N a_{ij} - 1 \right) \right] &= 0 \\ \frac{1}{a_{ij}} \cdot \sum_{t=1}^{T-1} P(O, i_t = q_i, i_{t+1} = q_j | \bar{\lambda}) + \eta &= 0 \\ \sum_{t=1}^{T-1} P(O, i_t = q_i, i_{t+1} = q_j | \bar{\lambda}) + \eta a_{ij} &= 0 \end{aligned} \quad (84)$$

利用 $\sum_{j=1}^N a_{ij} = 1$, 对上式两边求和可得:

$$\begin{aligned} \sum_{j=1}^N \sum_{t=1}^{T-1} P(O, i_t = q_i, i_{t+1} = q_j | \bar{\lambda}) + \sum_{j=1}^N \eta a_{ij} &= 0 \\ \sum_{t=1}^{T-1} P(O, i_t = q_i | \bar{\lambda}) + \eta \cdot 1 &= 0 \\ \eta &= - \sum_{t=1}^{T-1} P(O, i_t = q_i | \bar{\lambda}) \end{aligned} \quad (85)$$

将其带回 $\sum_{t=1}^{T-1} P(O, i_t = q_i, i_{t+1} = q_j | \bar{\lambda}) + \eta a_{ij} = 0$ 可得:

$$\begin{aligned} \sum_{t=1}^{T-1} P(O, i_t = q_i, i_{t+1} = q_j | \bar{\lambda}) - \sum_{t=1}^{T-1} P(O, i_t = q_i | \bar{\lambda}) \cdot a_{ij} &= 0 \\ a_{ij} &= \frac{\sum_{t=1}^{T-1} P(O, i_t = q_i, i_{t+1} = q_j | \bar{\lambda})}{\sum_{t=1}^{T-1} P(O, i_t = q_i | \bar{\lambda})} \end{aligned} \quad (86)$$

分子分母同时除以 $P(O | \bar{\lambda})$ 得:

$$a_{ij} = \frac{\frac{\sum_{t=1}^{T-1} P(O, i_t = q_i, i_{t+1} = q_j | \bar{\lambda})}{P(O | \bar{\lambda})}}{\frac{\sum_{t=1}^{T-1} P(O, i_t = q_i | \bar{\lambda})}{P(O | \bar{\lambda})}} = \frac{\sum_{t=1}^{T-1} P(i_t = q_i, i_{t+1} = q_j | O, \bar{\lambda})}{\sum_{t=1}^{T-1} P(i_t = q_i | O, \bar{\lambda})} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \quad (87)$$

其中, $\xi_t(i, j) = \frac{P(i_t = q_i, i_{t+1} = q_j, O | \bar{\lambda})}{\sum_{i=1}^N \sum_{j=1}^N P(i_t = q_i, i_{t+1} = q_j, O | \bar{\lambda})}$ 表示给定 $\bar{\lambda}$ 和 O , 在时刻 t 处于状态 q_i 且在时刻 $t+1$ 处于 q_j 的概率。

$$\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^N \alpha_t(j)\beta_t(j)}$$
 表示给定 $\bar{\lambda}$ 和 O , 在时刻 t 处于状态 q_i 的概率。

3. 求 b_{jk}

Q 函数中的第3项可以写成:

$$\begin{aligned} \sum_I P(O, I | \bar{\lambda}) \left(\sum_{t=1}^T \ln b_{i_t o_t} \right) &= \sum_{t=1}^T \left(\sum_{i_1, i_2, \dots, i_T} P(O, i_1, i_2, \dots, i_T | \bar{\lambda}) \ln b_{i_t o_t} \right) \\ &= \sum_{t=1}^T \left\{ \sum_{j=1}^N \left(\sum_{i_1, i_2, \dots, i_{t-1}, i_{t+1}, \dots, i_T} P(O, i_1, i_2, \dots, i_t = q_j, \dots, i_T | \bar{\lambda}) \ln b_{j o_t} \right) \right\} \\ &= \sum_{t=1}^T \left\{ \sum_{j=1}^N \left[\ln b_{j o_t} \cdot \left(\sum_{i_1, i_2, \dots, i_{t-1}, i_{t+1}, \dots, i_T} P(O, i_1, i_2, \dots, i_t = q_j, \dots, i_T | \bar{\lambda}) \right) \right] \right\} \\ &= \sum_{t=1}^T \sum_{j=1}^N \ln b_{j o_t} P(O, i_t = q_j | \bar{\lambda}) \end{aligned} \quad (88)$$

由于 b_{jk} 需要满足约束 $\sum_{k=1}^M b_{jk} = 1$, 同样利用拉格朗日乘子法, 写出拉格朗日函数:

$$\sum_{t=1}^T \sum_{j=1}^N \ln b_{j o_t} P(O, i_t = q_j | \bar{\lambda}) + \eta \left(\sum_{k=1}^M b_{jk} - 1 \right) \quad (89)$$

对拉格朗日函数关于 b_{jk} 求偏导并令结果为0:

$$\begin{aligned} \frac{\partial}{\partial b_{jk}} \left[\sum_{t=1}^T \sum_{j=1}^N \ln b_{j o_t} P(O, i_t = q_j | \bar{\lambda}) + \eta \left(\sum_{k=1}^M b_{jk} - 1 \right) \right] &= 0 \\ \frac{1}{b_{jk}} \cdot \sum_{t=1}^T P(O, i_t = q_j | \bar{\lambda}) \mathbb{I}(o_t = v_k) + \eta &= 0 \quad (\text{其中, } \mathbb{I}(o_t = v_k) \text{ 为指示函数}) \\ \sum_{t=1}^T P(O, i_t = q_j | \bar{\lambda}) \mathbb{I}(o_t = v_k) + \eta b_{jk} &= 0 \end{aligned} \quad (90)$$

利用 $\sum_{k=1}^M b_{jk} = 1$, 对上式两边关于 k 求和可得:

$$\begin{aligned} \sum_{k=1}^M \sum_{t=1}^T P(O, i_t = q_j | \bar{\lambda}) \mathbb{I}(o_t = v_k) + \sum_{k=1}^M \eta b_{jk} &= 0 \\ \sum_{t=1}^T P(O, i_t = q_j | \bar{\lambda}) + \eta \cdot 1 &= 0 \\ \eta &= - \sum_{t=1}^T P(O, i_t = q_j | \bar{\lambda}) \end{aligned} \quad (91)$$

公式说明: $\sum_{k=1}^M \sum_{t=1}^T P(O, i_t = q_j | \bar{\lambda}) \mathbb{I}(o_t = v_k) = \sum_{t=1}^T P(O, i_t = q_j | \bar{\lambda})$ 的原因: 每一时刻的 o_t 必然属于且仅属于 $v_k (k = 1, \dots, M)$ 中的一个。

将 v_k 遍历一遍, 所有时刻的 o_t 必然且仅能满足一次 $o_t = v_k$ 。

将其带回 $\sum_{t=1}^T P(O, i_t = q_j | \bar{\lambda}) \mathbb{I}(o_t = v_k) + \eta b_{jk} = 0$ 可得:

$$\begin{aligned} \sum_{t=1}^T P(O, i_t = q_j | \bar{\lambda}) \mathbb{I}(o_t = v_k) - \sum_{t=1}^T P(O, i_t = q_j | \bar{\lambda}) \cdot b_{jk} &= 0 \\ b_{jk} &= \frac{\sum_{t=1}^T P(O, i_t = q_j | \bar{\lambda}) \mathbb{I}(o_t = v_k)}{\sum_{t=1}^T P(O, i_t = q_j | \bar{\lambda})} \end{aligned} \quad (92)$$

分子分母同时除以 $P(O | \bar{\lambda})$:

$$\begin{aligned} b_{jk} &= \frac{\frac{\sum_{t=1}^T P(O, i_t = q_j | \bar{\lambda}) \mathbb{I}(o_t = v_k)}{P(O | \bar{\lambda})}}{\frac{\sum_{t=1}^T P(O, i_t = q_j | \bar{\lambda})}{P(O | \bar{\lambda})}} \\ &= \frac{\sum_{t=1}^T P(i_t = q_j | O, \bar{\lambda}) \mathbb{I}(o_t = v_k)}{\sum_{t=1}^T P(i_t = q_j | O, \bar{\lambda})} \\ &= \sum_{t=1, o_t = v_k}^T \gamma_t(j) \end{aligned} \quad (93)$$

$$\overline{\gamma} = \overline{\sum_{t=1}^T \gamma_t(j)}$$

其中, $\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^N \alpha_t(j)\beta_t(j)}$ 表示给定 $\bar{\lambda}$ 和 O , 在时刻 t 处于状态 q_i 的概率。

4. 预测问题

4.1. 贪心算法

在每个时刻 t 选择在该时刻最有可能出现的状态 i_t^* , 从而得到一个状态序列 $I^* = (i_1^*, i_2^*, \cdots, i_T^*)$, 将它作为预测的结果。具体算法那如下:

算法 **1.2** (贪心算法预测状态序列)

输入: 隐马尔可夫模型 λ , 观测序列 O

输出: 状态序列 $I^* = (i_1^*, i_2^*, \cdots, i_T^*)$

- 对时刻 $t = 1, 2, \cdots, T$
 - 计算在时刻 t 处于状态 q_i 的概率: $\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^N \alpha_t(j)\beta_t(j)}$
 - 在时刻 t 最有可能的状态: $i_t^* = \arg \max_{1 \leq i \leq N} [\gamma_t(i)]$, $t = 1, 2, \dots, T$
- 得到状态序列 $I^* = (i_1^*, i_2^*, \cdots, i_T^*)$

4.2. 维特比算法

维特比算法: 使用动态规划求解概率最大路径, 每一条路径对应一个状态序列。具体算法如下:

算法 **1.3** (维特比算法预测状态序列)

输入: 隐马尔可夫模型 λ , 观测序列 O

输出: 状态序列 $I^* = (i_1^*, i_2^*, \cdots, i_T^*)$

定义在时刻 t 状态为 q_i 的所有单个路径中概率最大值为:

- $\delta_t(i) = \max_{i_1, i_2, \dots, i_{t-1}} P(o_1, \dots, o_t, i_1, \dots, i_{t-1}, i_t = q_i), \quad i = 1, 2, \dots, N$
 - 在 $t = 1$ 时刻, 可知: $\delta_1(i) = \pi_i b_{io_1}$
对时刻 $t = 1, 2, \cdots, T$
 - $\delta_t(i) = \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}] b_{io_t}, i = 1, 2, \cdots, N$

定义在时刻 t 状态为 q_i 的所有单个路径中, 概率最大的路径中的第 $t - 1$ 个节点为:

- $\psi_t(i) = \arg \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}]$
 - 在 T 时刻, 可知: $i_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$
在时刻 $t = T - 1, T - 2, \cdots, 1$
 - $i_t^* = \psi_{t+1}(i_{t+1}^*)$
- 得到状态序列 $I^* = (i_1^*, i_2^*, \cdots, i_T^*)$

5. 例题：盒子和球模型

假设有3个盒子, 每个盒子里面都装有**红白**两种颜色的球, 盒子里的红白球数如下表所示:

盒子	1	2	3
红球数	5	4	7
白球数	5	6	3

(96)

按照如下规则抽球, 从而产生一个**球的颜色**的观测序列: 首先以0.2、0.4、0.4的概率从1、2、3号盒子中选取一个盒子, 从这个盒子里随机抽出1个球, 记录其颜色后放回, 然后按以下概率**选取下一个盒子**:

盒子	1	2	3
1	0.5	0.2	0.3
2	0.3	0.5	0.2
3	0.2	0.3	0.5

(97)

确定了转移的盒子后, 再从盒子里随机抽出1个球, 记录其颜色后放回。

重复3次, 最终得到的观测序列为O={红, 白, 红}。

记选取的**盒子序列**为**状态序列**, 试求最优状态序列, 即最优路径 $I^* = (i_1^*, i_2^*, \cdots, i_T^*)$

解：

该问题为典型的隐马尔可夫模型，由题意可得知模型的参数为：

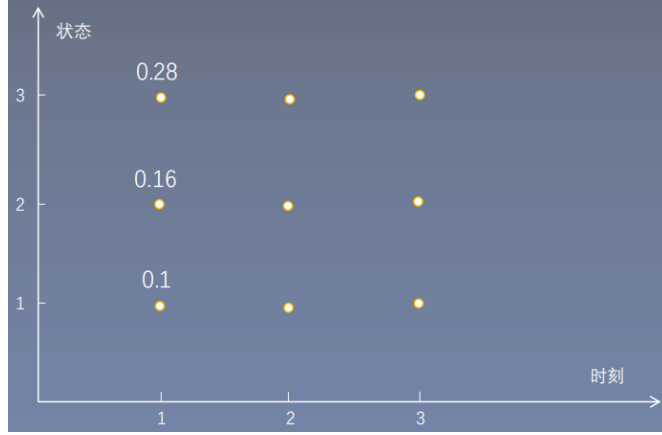
$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix} \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix} \quad \pi = (0.2, 0.4, 0.4)^T \quad (98)$$

$$O = \{\text{红, 白, 红}\}$$

按照维特比算法我们可以进行如下计算：


1. $t = 1$

$$\begin{aligned} \delta_1(1) &= \pi_1 b_{1o_1} = 0.2 \times 0.5 = 0.1, & \psi_1(1) &= 0 \\ \delta_1(2) &= \pi_2 b_{2o_1} = 0.4 \times 0.4 = 0.16, & \psi_1(2) &= 0 \\ \delta_1(3) &= \pi_3 b_{3o_1} = 0.4 \times 0.7 = 0.28, & \psi_1(3) &= 0 \end{aligned} \quad (99)$$




2. $t = 2$

$$\begin{aligned} \delta_2(1) &= \max_{1 \leq j \leq 3} [\delta_1(j) a_{j1}] b_{1o_2} = \max \begin{cases} 0.1 \times 0.5 = 0.05 \\ 0.16 \times 0.3 = 0.048 \\ 0.28 \times 0.2 = 0.056 \end{cases} \times 0.5 = 0.028, & \psi_2(1) &= \arg \max_{1 \leq j \leq 3} [\delta_1(j) a_{j1}] = 3 \\ \delta_2(2) &= \max_{1 \leq j \leq 3} [\delta_1(j) a_{j2}] b_{2o_2} = \max \begin{cases} 0.1 \times 0.2 = 0.02 \\ 0.16 \times 0.5 = 0.08 \\ 0.28 \times 0.3 = 0.084 \end{cases} \times 0.6 = 0.0504, & \psi_2(2) &= \arg \max_{1 \leq j \leq 3} [\delta_1(j) a_{j2}] = 3 \\ \delta_2(3) &= \max_{1 \leq j \leq 3} [\delta_1(j) a_{j3}] b_{3o_2} = \max \begin{cases} 0.1 \times 0.3 = 0.03 \\ 0.16 \times 0.2 = 0.032 \\ 0.28 \times 0.5 = 0.14 \end{cases} \times 0.3 = 0.042, & \psi_2(3) &= \arg \max_{1 \leq j \leq 3} [\delta_1(j) a_{j3}] = 3 \end{aligned} \quad (100)$$



3. $t = 3$

$$\begin{aligned} \delta_3(1) &= \max_{1 \leq j \leq 3} [\delta_2(j) a_{j1}] b_{1o_3} = \max \begin{cases} 0.028 \times 0.5 = 0.014 \\ 0.0504 \times 0.3 = 0.01512 \\ 0.042 \times 0.2 = 0.0084 \end{cases} \times 0.5 = 0.00756, & \psi_3(1) &= \arg \max_{1 \leq j \leq 3} [\delta_2(j) a_{j1}] = 2 \\ \delta_3(2) &= \max_{1 \leq j \leq 3} [\delta_2(j) a_{j2}] b_{2o_3} = \max \begin{cases} 0.028 \times 0.2 = 0.0056 \\ 0.0504 \times 0.5 = 0.0252 \\ 0.042 \times 0.3 = 0.0126 \end{cases} \times 0.4 = 0.01008, & \psi_3(2) &= \arg \max_{1 \leq j \leq 3} [\delta_2(j) a_{j2}] = 2 \\ \delta_3(3) &= \max_{1 \leq j \leq 3} [\delta_2(j) a_{j3}] b_{3o_3} = \max \begin{cases} 0.028 \times 0.3 = 0.0084 \\ 0.0504 \times 0.2 = 0.01008 \\ 0.042 \times 0.5 = 0.021 \end{cases} \times 0.7 = 0.0147, & \psi_3(3) &= \arg \max_{1 \leq j \leq 3} [\delta_2(j) a_{j3}] = 3 \end{aligned} \quad (101)$$



所以，最优状态序列为：

$$\begin{aligned}
 i_3^* &= \arg \max_i [\delta_3(i)] = 3 \\
 i_2^* &= \psi_3(i_3^*) = \psi_3(3) = 3 \\
 i_1^* &= \psi_2(i_2^*) = \psi_2(3) = 3
 \end{aligned} \tag{102}$$

6. 参考文档

1. [如何理解隐马尔科夫模型\(HMM\)后向算法初始值为1? - 知乎\(zhihu.com\)](https://zhuanlan.zhihu.com/p/100000000).