Luong Attention

2022-05-07

1. Attention 架构

Luong Attention分为Local和Global两种，本文主要分析Global Attention。下图为Global Attention的架构图：

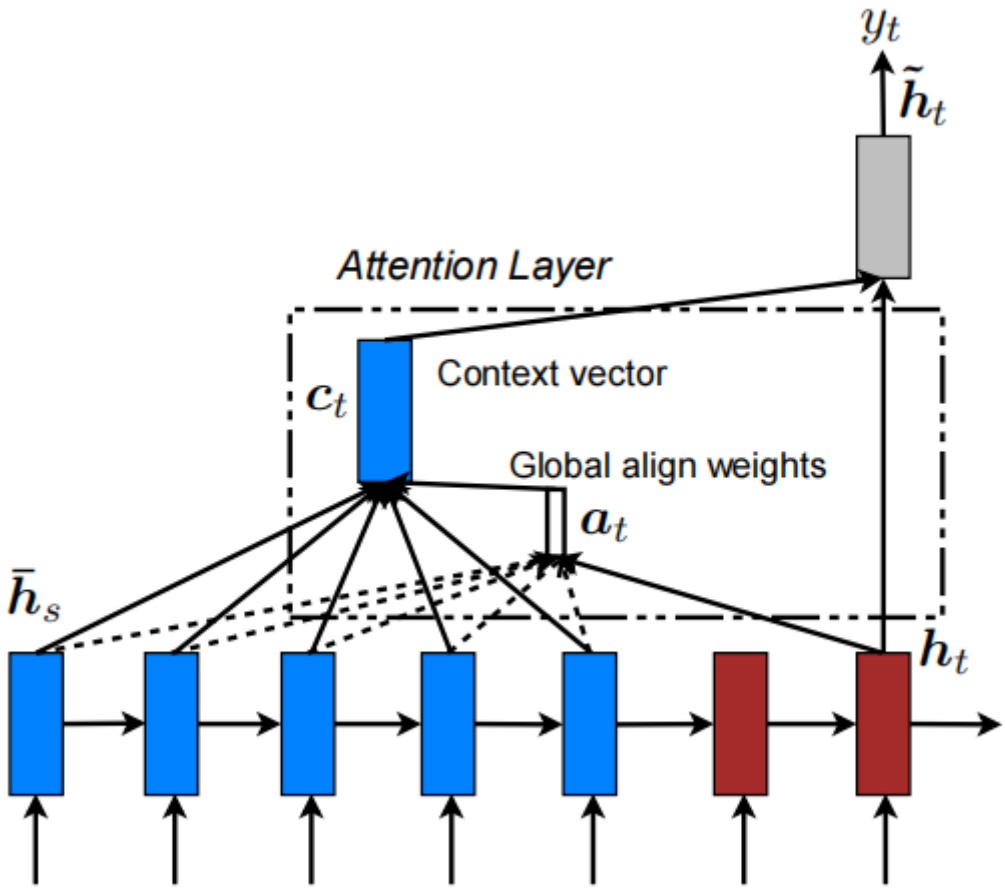

符号解释：

1. $\bar{h}_s $：encoder_output
2. h_t：decoder_output
3. $a_t(s)$：attn_weights
4. c_t：Context vector
5. $\tilde{h}_s$：可视为new decoder hidden state

以中英文翻译场景为例，根据该架构图，分为如下计算步骤：

1. attn_weights计算

   通过encoder_output和decoder_output计算得到attn_weights，即a_t

2. Context vector计算

   通过encoder_output和a_t计算得到加权encoder_output，即c_t

3. New decoder hidden state计算

   将c_t和decoder_output进行cat合并，经过tanh和linear变换处理得到新的decoder_output，即$\tilde{h}_s$

4. 预测

   根据$\tilde{h}_s$进行预测，得到最终预测结果。

2. Attention计算流程

Global Attention计算流程如下图所示：

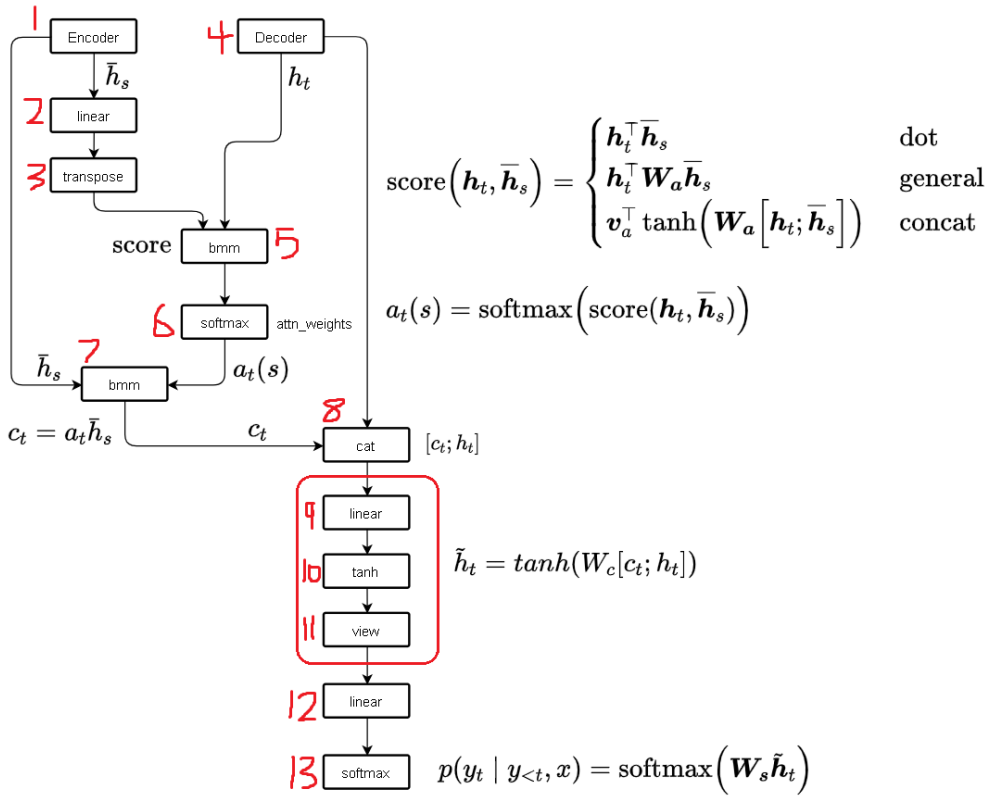

计算步骤如下：

1. Encoder
   - step1：对原始输入，通过RNN（如LSTM）处理，得到encoder_output：

     $\bar{h}_s$：$[\text{batch\_size}, \text{input\_len}, \text{enc\_hidden\_size}]$
   - step2：为了能够使得encoder_output和decoder_output做bmm运算，需要进行linear处理

     $\bar{h}_s$：$[\text{batch\_size}, \text{input\_len}, \text{dec\_hidden\_size}]$

- step3：transpose(1,2)

  $\bar{h}_s$：$[\text{batch\_size}, \text{dec\_hidden\_size}, \text{input\_len}]$

2. Decoder
   - RNN
     - step4：对Decoder端的输入，通过RNN（如LSTM）处理，得到decoder_output：

       h_t：$[\text{batch\_size}, \text{output\_len}, \text{dec\_hidden\_size}]$
   - Attention
     - step5：基于h_t和$\bar{h}_s$，进行打分计算：

       $\text{score}(h_t, \bar{h}_s) = \text{bmm}(h_t, \bar{h}_s)$：$[\text{batch\_size}, \text{output\_len}, \text{input\_len}]$
     - step6： 对打分结果通过softmax计算，得到attn_weights

       $a_t(s) = \text{align}(\text{h}_\text{t}, \bar{\text{h}}_\text{s}) = \text{softmax}\left(\text{score}(\text{h}_\text{t}, \bar{\text{h}}_\text{s})\right)$：$[\text{batch\_size}, \text{output\_len}, \text{input\_len}]$
     - step7： 基于$a_t(s)$，对encoder_output求加权平均

       $c_t = a_t\bar{h}_s$：$[\text{batch\_size}, \text{output\_len}, \text{enc\_hidden\_size}]$
   - New Hidden
     - step8：将加权encoder_output通过cat操作"融入"到原始的decoder_output

       $[c_t; h_t]$： $[\text{batch\_size}, \text{output\_len}, \text{enc\_hidden\_size} + \text{dec\_hidden\_size}]$

       为了方面后续的linear变换，需要对其shape进行调整，结果如下：

       $[c_t; h_t]$： $[\text{batch\_size} \times \text{output\_len}, \text{enc\_hidden\_size} + \text{dec\_hidden\_size}]$
     - step9：对$[c_t; h_t]$进行linear变换

       $\text{linear}([c_t; h_t])$：：$[\text{batch\_size} \times \text{output\_len}, \text{dec\_hidden\_size}]$
     - step10：$\tanh$变换

       $\tanh(\text{linear}([c_t; h_t]))$：：$[\text{batch\_size} \times \text{output\_len}, \text{dec\_hidden\_size}]$
     - step11：维度展开，将二维展开到三维

       $\tilde{h}_s$： $[\text{batch\_size}, \text{output\_len}, \text{dec\_hidden\_size}]$
   - Predict
     - step12：对$\tilde{h}_s$进行linear变换

       $\text{linear}(\tilde{h}_s)$： $[\text{batch\_size}, \text{output\_len}, \text{vocab\_size}]$
     - step13：通过softmax运算，得到最终预测概率结果

       $\text{softmax}(\text{linear}(\tilde{h}_s))$： $[\text{batch\_size}, \text{output\_len}, \text{vocab\_size}]$

3. 参考资料

1. 第七课 Seq2Seq与Attention (julyedu.com)