# Luong Attention

2022-05-07



## 1. Attention 架构

Luong Attention分为Local和Global两种，本文主要分析Global Attention。下图为Global Attention的架构图：

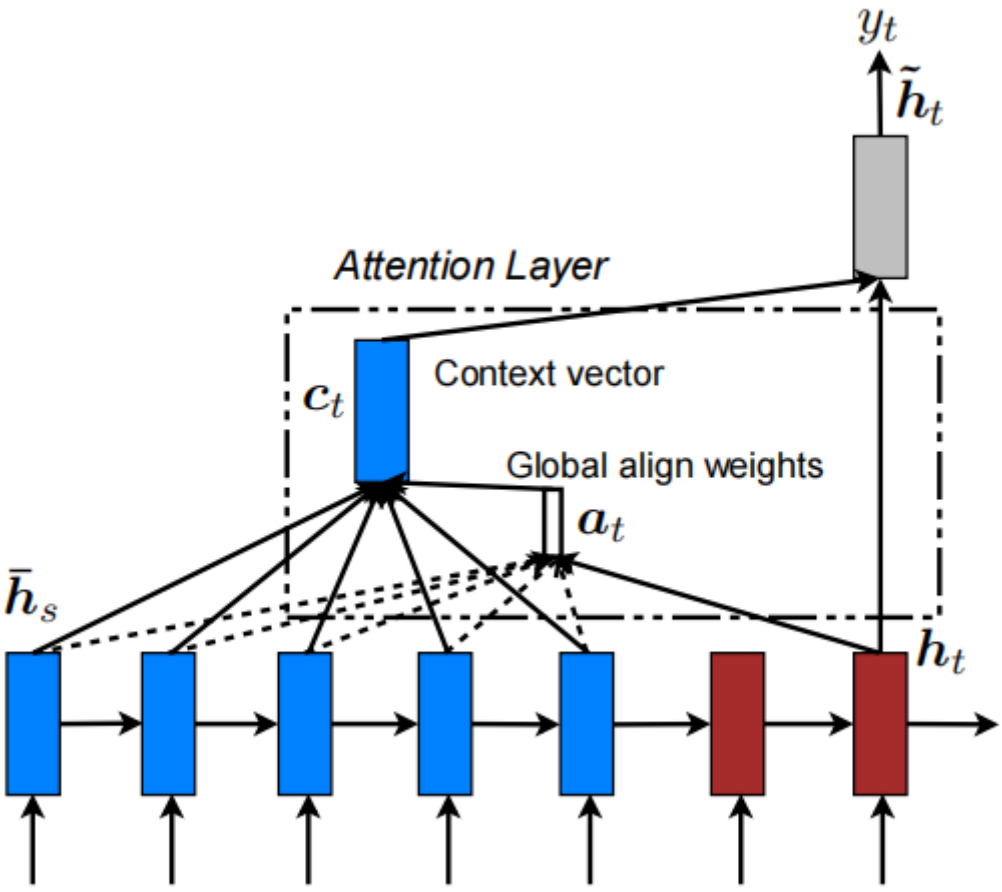


符号解释：

1. $\bar{h}_s$：encoder_output
2. $h_t$：decoder_output
3. $a_t(s)$：attn_weights
4. $c_t$：Context vector
5. $\tilde{h}_s$：可视为new decoder hidden state

以中英文翻译场景为例，根据该架构图，分为如下计算步骤：

1. attn_weights计算

   通过encoder_output和decoder_output计算得到attn_weights，即$a_t$

2. Context vector计算

   通过encoder_output和$a_t$计算得到加权encoder_output，即$c_t$

3. New decoder hidden state计算

   将$c_t$和decoder_output进行cat合并，经过tanh和linear变换处理得到新的decoder_output，即$\tilde{h}_s$

4. 预测

   根据$\tilde{h}_s$进行预测，得到最终预测结果。

# 2. Attention计算流程

Global Attention计算流程如下图所示：

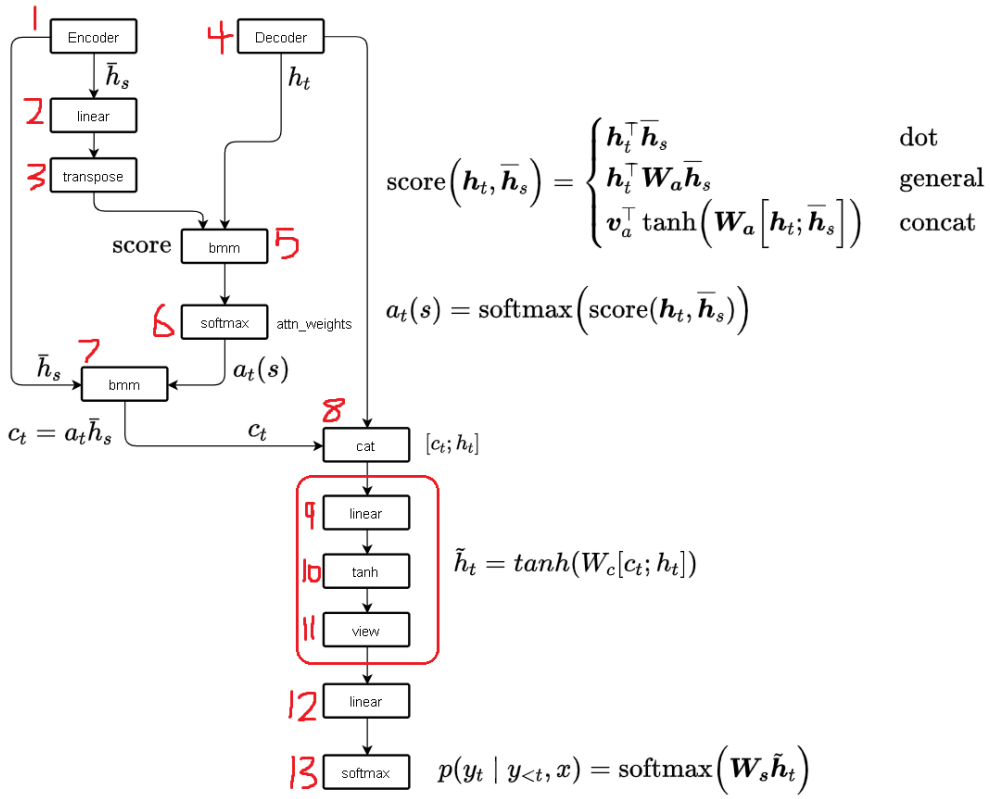


计算步骤如下：

1. Encoder
   - step1：对原始输入，通过RNN（如LSTM）处理，得到encoder_output：

     $\bar{h}_s$：$[\text{batch\_size}, \text{input\_len}, \text{enc\_hidden\_size}]$
   - step2：为了能够使得encoder_output和decoder_output做bmm运算，需要进行linear处理

     $\bar{h}_s$：$[\text{batch\_size}, \text{input\_len}, \text{dec\_hidden\_size}]$

- step3：transpose(1,2)

  $\bar{h}_s$：$[\text{batch\_size}, \text{dec\_hidden\_size}, \text{input\_len}]$

2. Decoder
   - RNN
     - step4：对Decoder端的输入，通过$\text{RNN}$（如$\text{LSTM}$）处理，得到decoder_output：

       $h_t$：$[\text{batch\_size}, \text{output\_len}, \text{dec\_hidden\_size}]$
   - Attention
     - step5：基于$h_t$和$\bar{h}_s$，进行打分计算：

       $\text{score}(h_t, \bar{h}_s) = \text{bmm}(h_t, \bar{h}_s)$：$[\text{batch\_size}, \text{output\_len}, \text{input\_len}]$
     - step6：对打分结果通过$\text{softmax}$计算，得到attn_weights

       $a_t(s) = \text{align}(\text{h}_\text{t}, \bar{\text{h}}_\text{s}) = \text{softmax}\left(\text{score}(\text{h}_\text{t}, \bar{\text{h}}_\text{s})\right)$：$[\text{batch\_size}, \text{output\_len}, \text{input\_len}]$
     - step7：基于$a_t(s)$，对encoder_output求加权平均

       $c_t = a_t\bar{h}_s$：$[\text{batch\_size}, \text{output\_len}, \text{enc\_hidden\_size}]$
   - New Hidden
     - step8：将加权encoder_output通过$\text{cat}$操作"融入"到原始的decoder_output

       $[c_t; h_t]$：$[\text{batch\_size}, \text{output\_len}, \text{enc\_hidden\_size} + \text{dec\_hidden\_size}]$

       为了方面后续的$\text{linear}$变换，需要对其shape进行调整，结果如下：

       $[c_t; h_t]$：$[\text{batch\_size} \times \text{output\_len}, \text{enc\_hidden\_size} + \text{dec\_hidden\_size}]$
     - step9：对$[c_t; h_t]$进行$\text{linear}$变换

       $\text{linear}([c_t; h_t])$：$[\text{batch\_size} \times \text{output\_len}, \text{dec\_hidden\_size}]$
     - step10：$\tanh$变换

       $\tanh(\text{linear}([c_t; h_t]))$：$[\text{batch\_size} \times \text{output\_len}, \text{dec\_hidden\_size}]$
     - step11：维度展开，将二维展开到三维

       $\tilde{h}_s$：$[\text{batch\_size}, \text{output\_len}, \text{dec\_hidden\_size}]$
   - Predict
     - step12：对$\tilde{h}_s$进行$\text{linear}$变换

       $\text{linear}(\tilde{h}_s)$：$[\text{batch\_size}, \text{output\_len}, \text{vocab\_size}]$
     - step13：通过$\text{softmax}$运算，得到最终预测概率结果

       $\text{softmax}(\text{linear}(\tilde{h}_s))$：$[\text{batch\_size}, \text{output\_len}, \text{vocab\_size}]$

# 3. 参考资料


1. 第七课 Seq2Seq与Attention (julyedu.com)